분자 예측 벤치마크는 일반화 능력을 평가하는가

Most Ligand-Based Classification Benchmarks Reward Memorization Rather than Generalization

Izhar Wallach and Abraham Heifets
J. Chem. Inf. Model. 2018, 58, 916–932

연구 질문과 핵심 결론

연구 질문 높은 AUC는 새로운 분자의 예측 능력을 반영하는가?

접근 활성·비활성 분자의 학습–평가 유사성을 AVE로 정량화

결과 여러 벤치마크에서 AVE bias와 AUC가 강하게 상관

평가 데이터의 구성 자체가 예측을 쉽게 만들 수 있다

Abstract, pp. 916–918

벤치마크의 유사성 편향

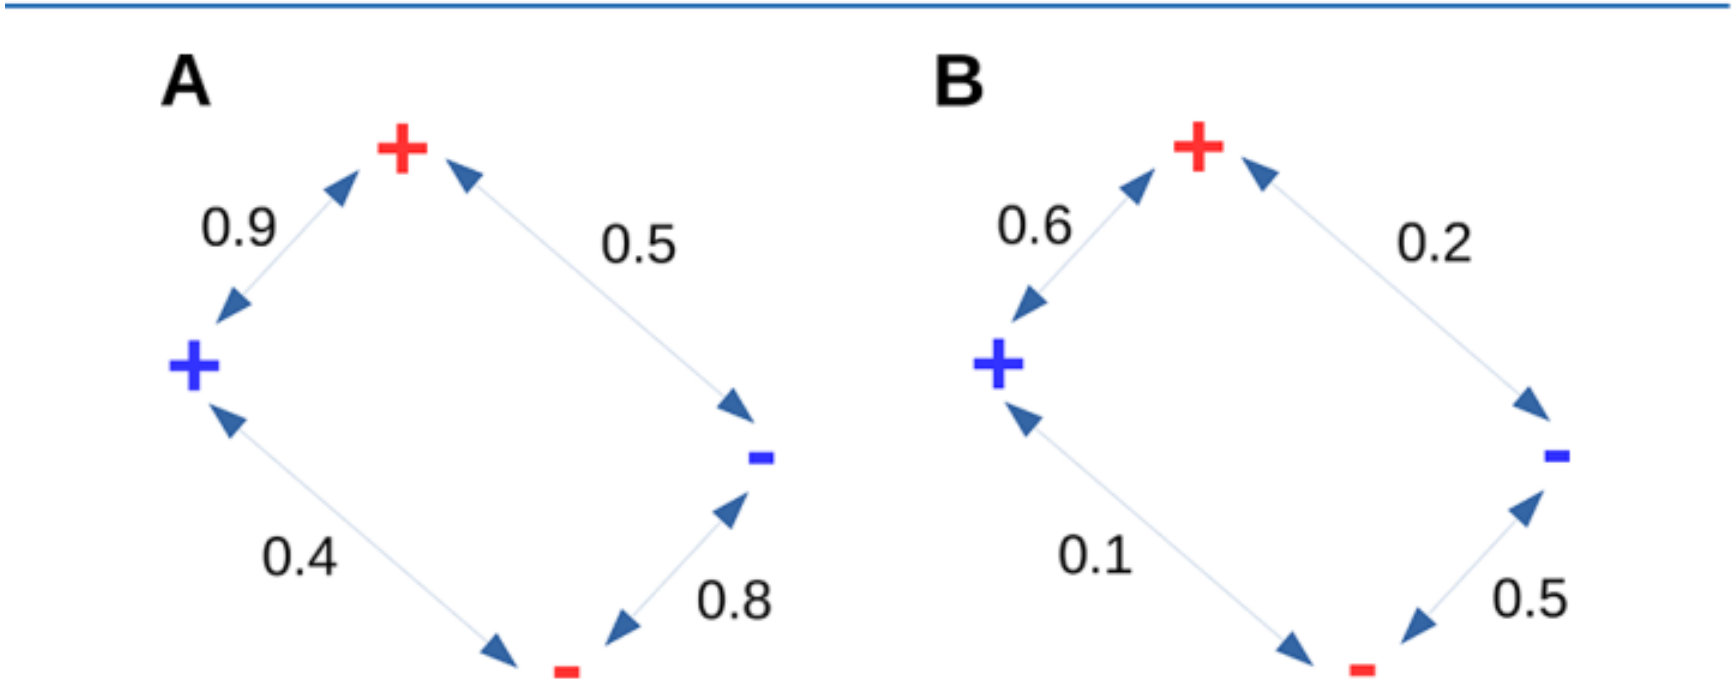
화학 데이터는 알려진 활성 주변의 유사체에 집중되는 경향이 있다

분자 중복을 제거해도 유사한 계열이 학습·평가에 함께 남을 수 있다

분류기는 활성 패턴과 비활성 패턴을 모두 이용한다

비활성 분자의 분포도 평가 난이도를 결정한다

절대 유사도와 상대 유사도의 차이



절대 유사도가 낮아도, 같은 클래스가 더 가까우면 분류가 쉬워진다

A와 B의 유사도 차이는 모두 0.8 · 파랑 학습 / 빨강 평가

Figure 1, p. 917

AVE 계산에 사용하는 네 가지 집합

항	평가 집합	비교할 학습 집합	의미
AA	활성 V_a	활성 T_a	활성끼리의 근접성
AI	활성 V_a	비활성 T_i	활성과 비활성의 근접성
II	비활성 V_i	비활성 T_i	비활성끼리의 근접성
IA	비활성 V_i	활성 T_a	비활성과 활성의 근접성

AVE는 두 클래스의 상대적 근접성을 함께 비교한다

Methods, p. 918

거리 분포를 하나의 값으로 요약

$$S(V,T,d) = 1/|V| \sum_v I[\text{최근접 이웃 거리} < d]$$

$$H(V,T) = 1/|D| \sum_{d \in D} S(V,T,d)$$

D = {0, 0.01, …, 1} · 기본 거리 = 1 − Tanimoto similarity

가까운 학습 이웃이 많을수록 H 값이 커진다

Methods, p. 918

AVE bias의 해석

$$B = (AA - AI) + (II - IA)$$

값	거리 구조의 해석
양수	같은 클래스의 학습 분자가 상대적으로 가깝다
0에 가까움	두 상대 근접성 차이의 합이 작다
음수	다른 클래스의 학습 분자가 더 가까운 경향

총합뿐 아니라 활성·비활성 항을 따로 확인해야 한다

Methods, p. 918

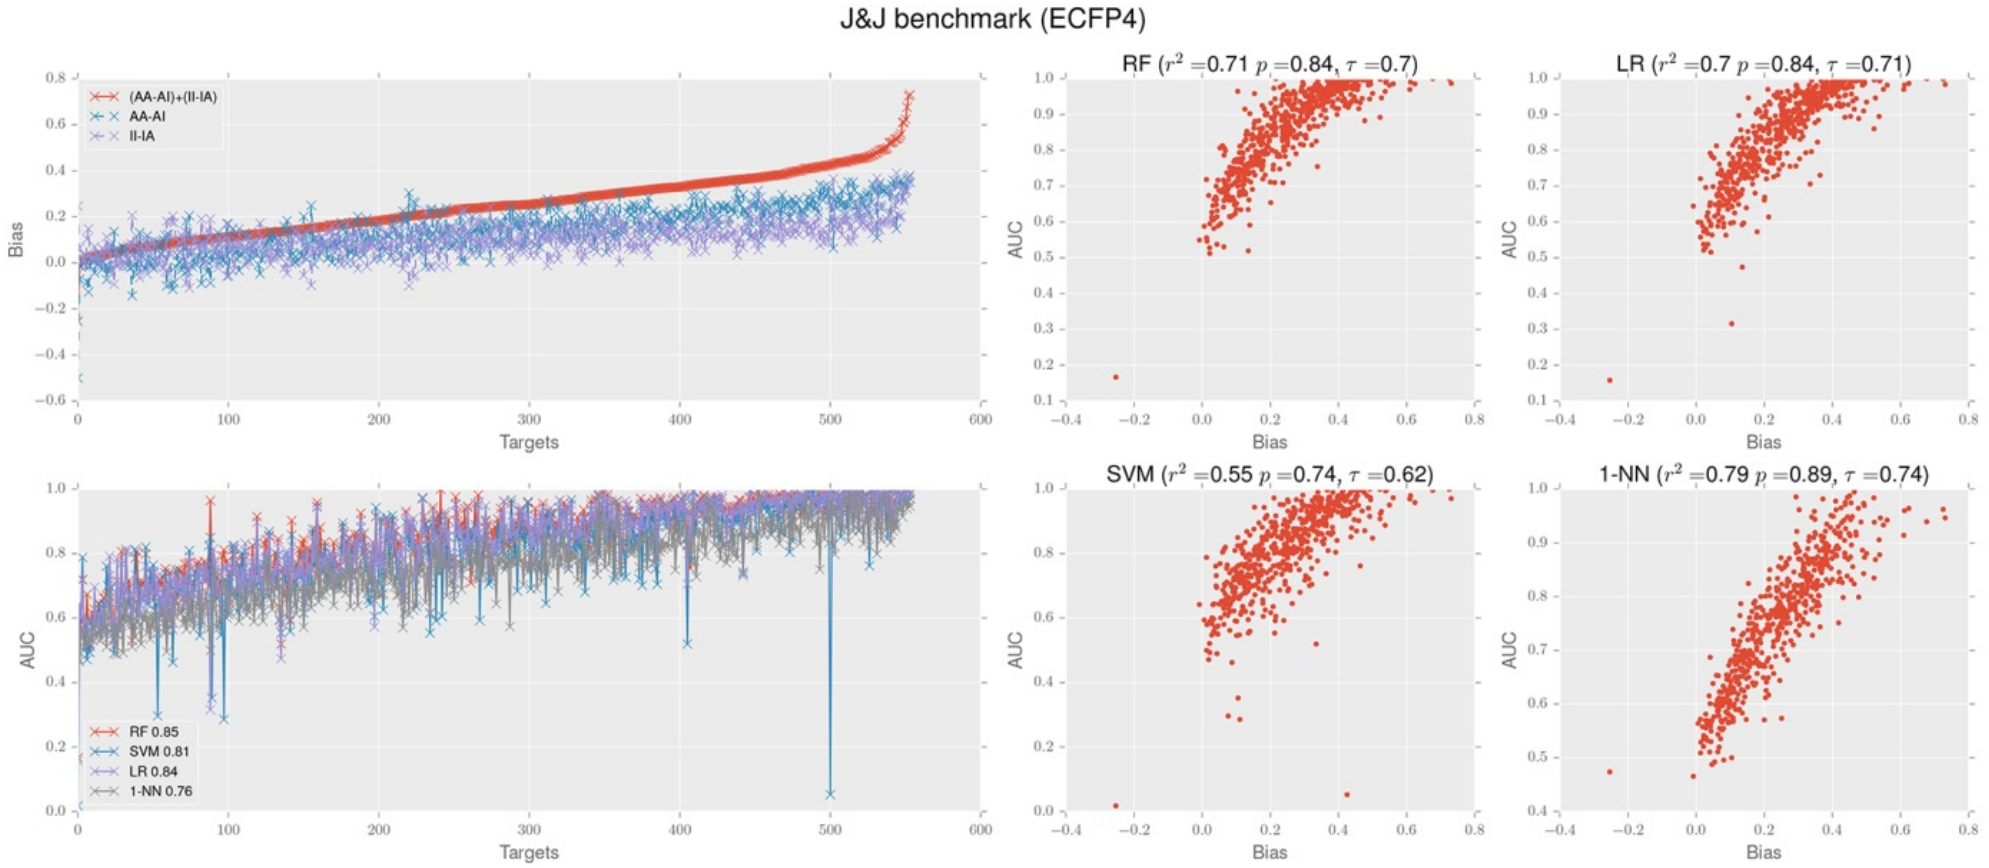
분석 데이터와 예측 모델

분석 데이터	과제 수	원래 분할·편향 완화 방식
J&J / MUV	560 / 17	유사도 클러스터 / MUV 설계 후 무작위 분할
ChEMBL / Tox21	42 / 10	버전 기반 시간 분할 근사 / 제공 분할
PCBA / ToxCast / SIDER	128 / 617 / 27	무작위 분할과 generic Murcko 분할
Merck internal	21	학습 활성과 비유사한 내부 활성 + decoys

공통 모델 **RF · LR · SVM · 1-NN**

Results, pp. 918–926

J&J에서 AVE와 AUC가 함께 증가



RF 평균 AUC 0.85 · AVE–AUC Pearson ρ = 0.84, r^2 = 0.71

Figure 2, pp. 918–920

단순한 분자 특성으로도 높은 AUC

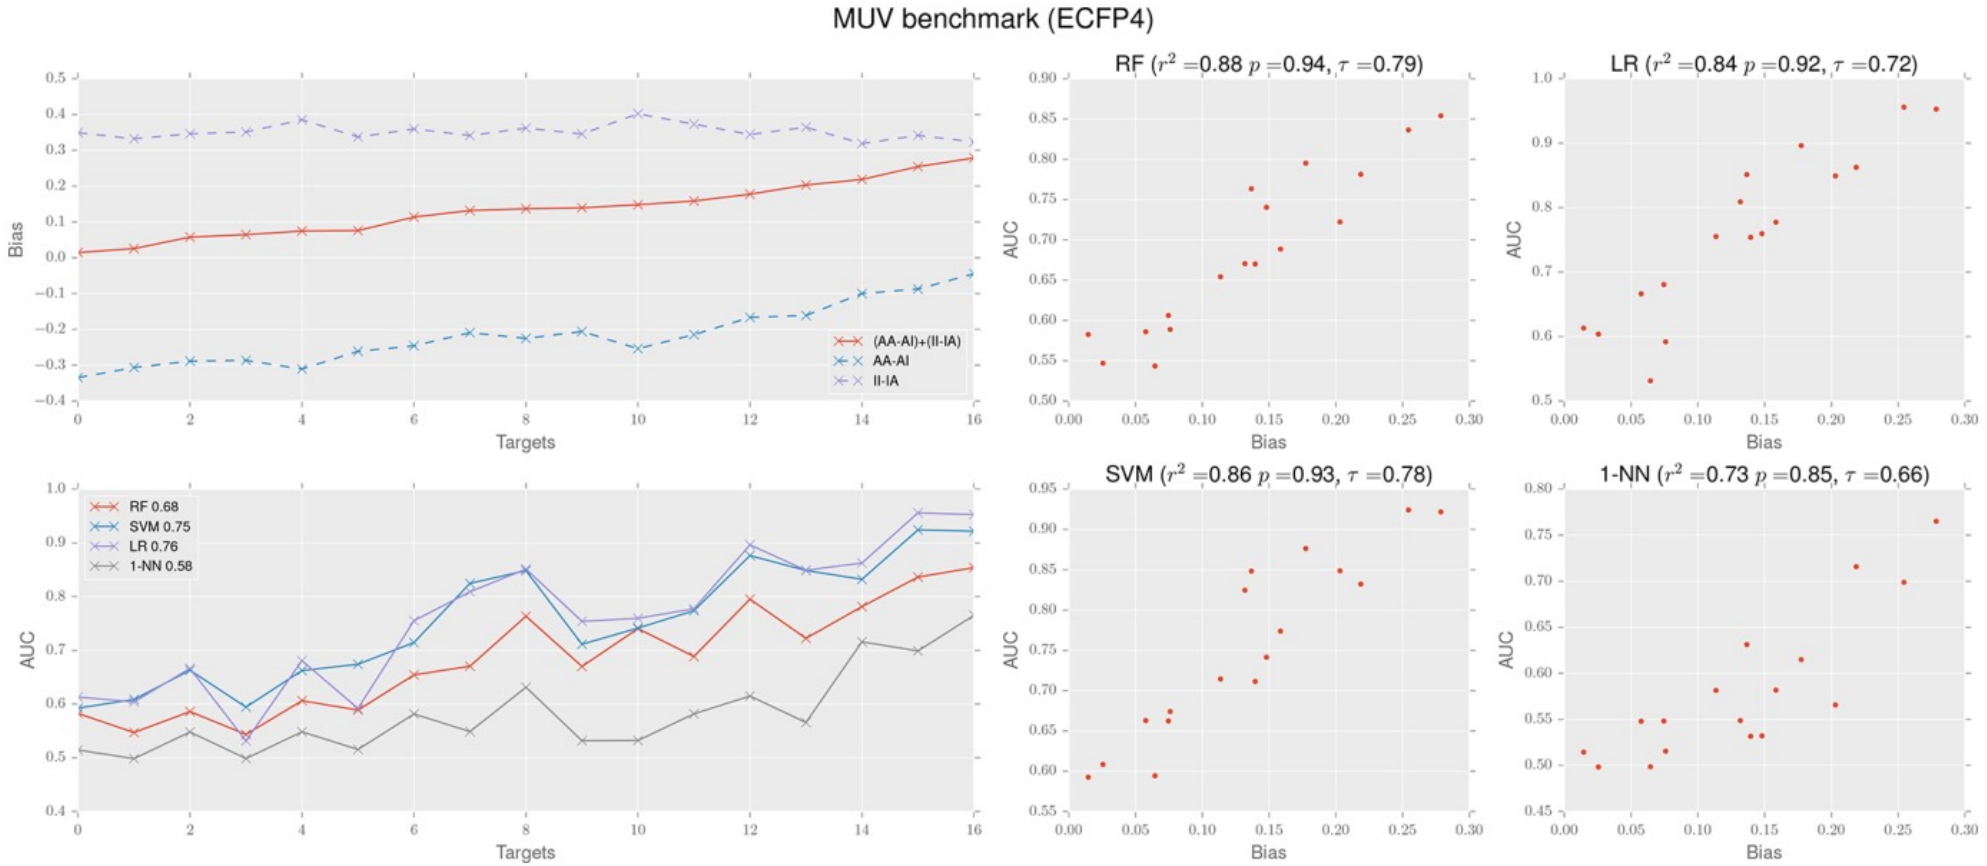
J&J 지문	RF	SVM	LR	1-NN
ECFP4	0.85	0.81	0.84	0.76
MACCS	0.82	0.78	0.79	0.72
MUV simple	0.78	0.75	0.74	0.57

MUV simple은 원자 수와 일부 분자 물성으로 구성

단순 특성의 성능도 데이터 구성에 대한 진단 근거가 된다

J&J analysis, Figure 3, pp. 919–920

MUV가 놓친 비활성 분자의 편향



활성 측 항은 음수, 비활성 측 항은 약 +0.4

Figure 4, p. 920

분할 방식을 바꾼 후에도 상관은 남는다

데이터·분할	RF r^2	LR r^2	SVM r^2	1-NN r^2
ChEMBL 시간 분할 근사	0.70	0.54	0.43	0.66
PCBA 무작위	0.55	0.70	0.66	0.62
PCBA generic Murcko	0.51	0.66	0.60	0.47
SIDER generic Murcko	0.51	0.63	0.50	0.64

PCBA RF 평균 AUC 무작위 0.84 / generic Murcko 0.81

Table 1, p. 927; PCBA results, p. 924

표적을 바꾼 대조 실험

학습 양성 다른 표적 X의 활성 분자

학습 음성 평가하려는 표적 Y의 비활성 분자

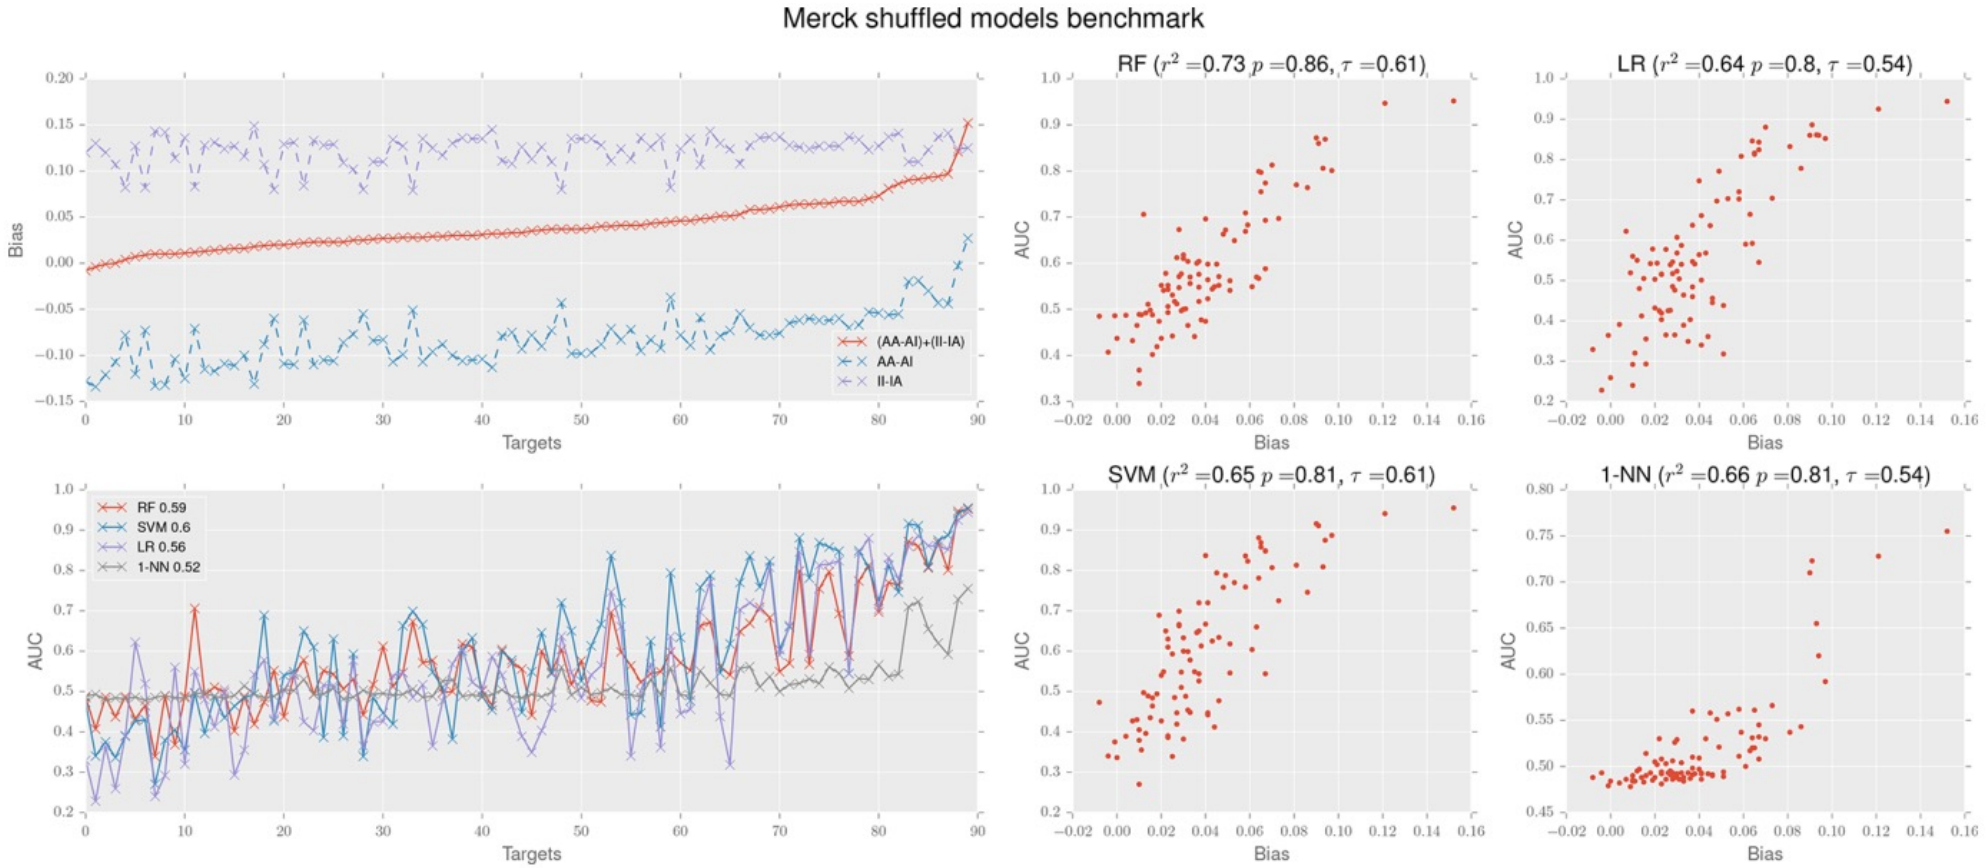
평가 대상 표적 Y의 활성·비활성 분자

X 활성과 Y 활성 사이 APFP Dice similarity ≤ 0.7

표적 Y의 활성 학습 데이터 없이도 성능이 나오는지 확인

Merck shuffled benchmark, Figure 15, p. 926

다른 표적의 데이터로도 일부 테스트는 쉽다



90개 조합 평균 AUC RF 0.59 / SVM 0.60 / LR 0.56 / 1-NN 0.52

Figure 15, p. 926; Figures 17–18, pp. 928–929

AVE를 낮추는 데이터 분할

목표 데이터를 최대한 유지하면서 AVE bias를 줄이는 분할

방법 유전 알고리즘으로 학습·평가 집합 배치를 탐색

보고 J&J 560개 중 약 400개 테스트에서 편향 감소

저자도 최적해·성공을 보장하지 않으며 새 편향의 가능성을 인정

Unbiasing, p. 929

결과 해석의 범위와 한계

AVE는 선택한 분자 표현과 거리 함수에 의존한다

분석 모델 RF, LR, SVM, 1-NN · 현대 딥러닝 전체를 직접 검증하지 않음

비판적 해석 상관관계만으로 모든 성능의 원인을 확정할 수 없다

비판적 해석 낮은 AVE가 실제 적용 분포나 일반화를 보장하지 않는다

Discussion, pp. 929–930; 발표자 비판적 해석

분자 예측 평가에 적용할 점

평가 단계	확인 항목
적용 목적 정의	기존 계열 최적화인지, 새로운 화학 공간 탐색인지
분할 진단	AVE, 활성·비활성 항, 학습–평가 유사도 분포
기준선 비교	1-NN 및 단순 분자 특성을 사용한 모델
최종 검증	선택에 사용하지 않은 외부·시간 분할 또는 전향적 데이터

분할 방식의 이름과 실제 데이터의 난이도를 함께 보고한다

Conclusion, p. 930; 적용 항목은 발표자 정리

결론

활성과 비활성 양쪽의 유사성 구조가 평가 성능에 영향을 준다

AVE bias는 여러 벤치마크의 AUC와 강하게 상관했다

새 분자에 대한 예측 능력은 목적에 맞는 독립 평가로 확인해야 한다

높은 AUC를 해석하려면 벤치마크의 구조도 확인해야 한다

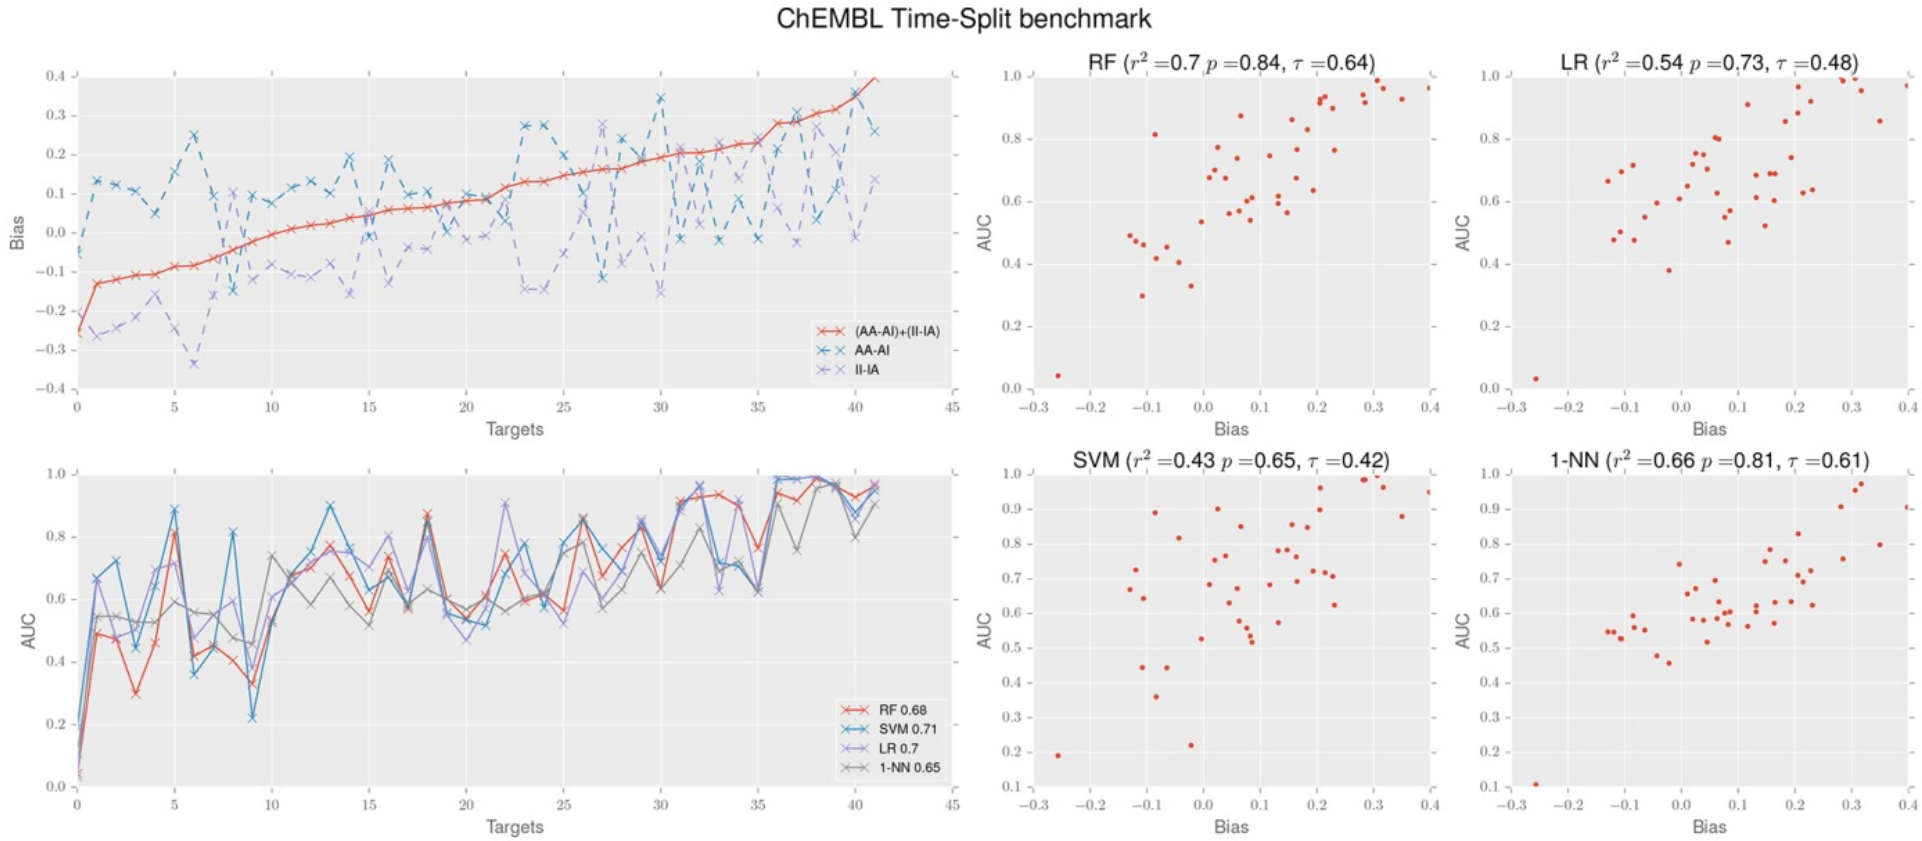
Wallach & Heifets, JCIM 2018, DOI 10.1021/acs.jcim.7b00403

보충 예상 질문

질문	답변 요지
AVE가 0이면 좋은 벤치마크인가?	거리 표현과 두 항의 상쇄, 실사용 분포를 함께 확인
1-NN보다 좋으면 일반화한 것인가?	기준선 개선은 의미가 있지만 독립 검증이 추가로 필요
시간 분할을 쓰면 해결되는가?	유사체가 시간 경계를 넘을 수 있고 측정 대상 선택도 편향됨
이 논문이 deep learning을 반박했나?	분석한 모델 범위와 현대 딥러닝 전체는 구분해야 함

Methods, p. 918; Discussion, pp. 929–930

보충 ChEMBL 시간 분할의 정확한 의미



v19 학습 / v20 신규 수록 데이터 평가 · 실제 실험 시점과 다를 수 있음

Figure 6, pp. 921–922