Boltz-2: Towards Accurate and Efficient Binding Affinity Prediction

Paper Review

Sieun Kim

flex

2026 Autumn

Outline

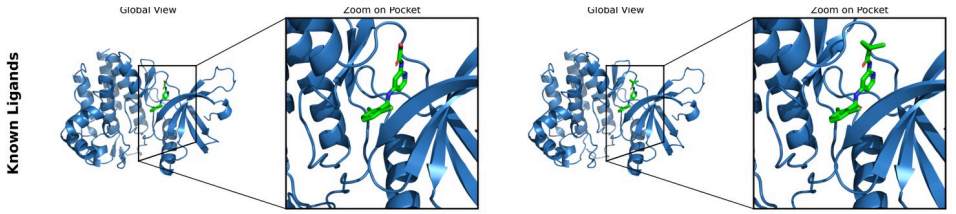
1. Background — 신약 후보 평가와 기존 방법
2. Method — 모델 구성, Structure / Confidence / Affinity training
3. Results — Structure , Affinity prediction 평가, TYK2 후보 탐색
4. Limitations
5. References

신약 후보에서 알고 싶은 정보

- **Target protein:** 약물이 작용하도록 목표로 삼은 단백질
- **Ligand:** 단백질에 결합하는 분자로, 이 연구에서는 주로 작은 약물 후보 분자
- **Binding affinity:** 단백질과 ligand 사이의 결합 강도

후보 평가에 필요한 정보

예측 대상	필요한 정보
Complex structure	Ligand의 결합 위치와 결합 자세인 pose
Binding affinity	해당 ligand가 단백질에 결합하는 강도



TYK2–ligand complex: global view와 pocket zoom-in (Fig. 16)

Boltz-2: Boltz-1의 구조 예측 능력을 바탕으로 **복합체 구조와 binding affinity를 함께 예측**하도록 확장한 AI 모델

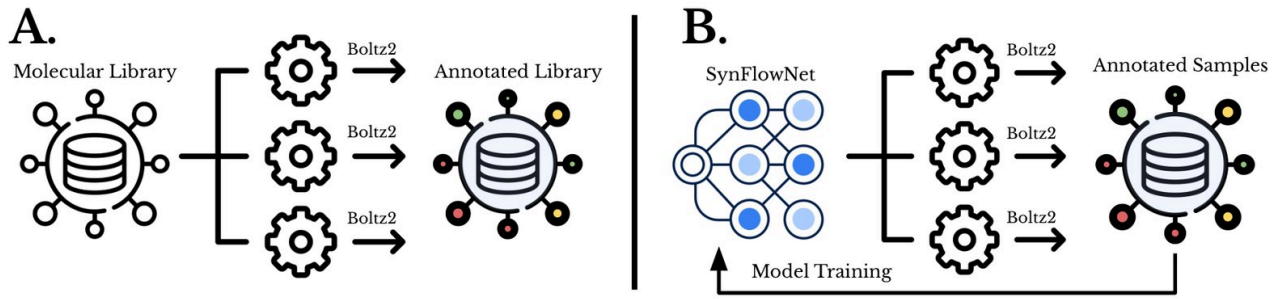
- 그럴듯한 결합 구조만으로 강한 결합을 판단하기 어려우므로 **affinity의 별도 예측 필요**

신약 탐색 단계와 예측 목표

단계	하는 일	필요한 예측
Hit discovery	대규모 후보에서 초기 활성 물질 선별	Binder와 non-binder 구분
Hit-to-lead	Hit를 개발 가치가 높은 lead로 발전	후보 간 affinity 비교
Lead optimization	Lead의 구조를 수정하여 결합력과 약물 특성 개선	유사 분자 간 작은 affinity 차이

후보 확보 방식

- **Library screening:** 기존 화합물 목록에서 후보 선별
- **De novo generation:** 생성 모델을 이용한 새로운 후보 분자 설계



A) Fixed-library screening B) Generative screening (Fig. 9)

공통적인 요구: 후보의 결합 가능성과 강도를 평가하여 후속 검토의 우선순위 설정

기존 방법: Docking과 FEP

Docking

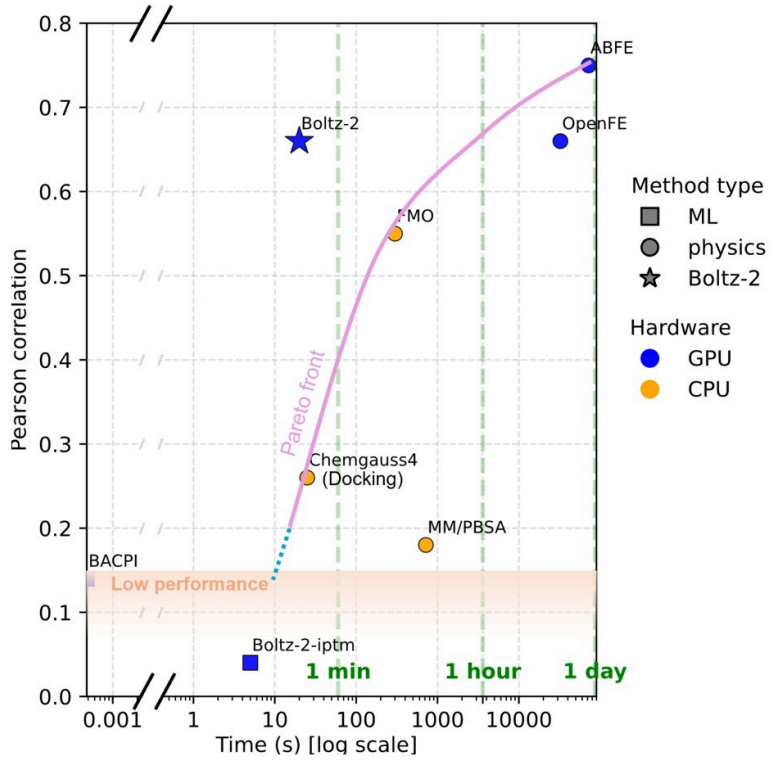
1. 단백질의 결합 부위에 ligand를 여러 pose로 배치
2. 분자의 모양과 상호작용을 scoring function으로 평가
3. 점수에 따른 후보 순위 결정

- **장점:** 빠른 계산을 통한 대규모 후보 선별
- **한계:** 단백질의 움직임과 용매 효과 등의 단순화에 따른 정밀한 affinity 예측의 어려움

FEP: Free-energy perturbation

1. Ligand의 상호작용을 여러 중간 상태에 걸쳐 단계적으로 변경
2. 각 상태에서 분자와 용매의 움직임을 sampling하여 자유에너지 차이 계산
3. 상대 FEP에서는 결합 상태와 용액 상태의 계산을 조합하여 ligand 간 affinity 차이 추정

- **높은 계산 비용:** 여러 중간 상태의 충분한 sampling과 반복 계산 필요
- **복잡한 준비:** Protonation state, force field, ligand 간 원자 대응 관계 설정 및 수렴 확인 필요



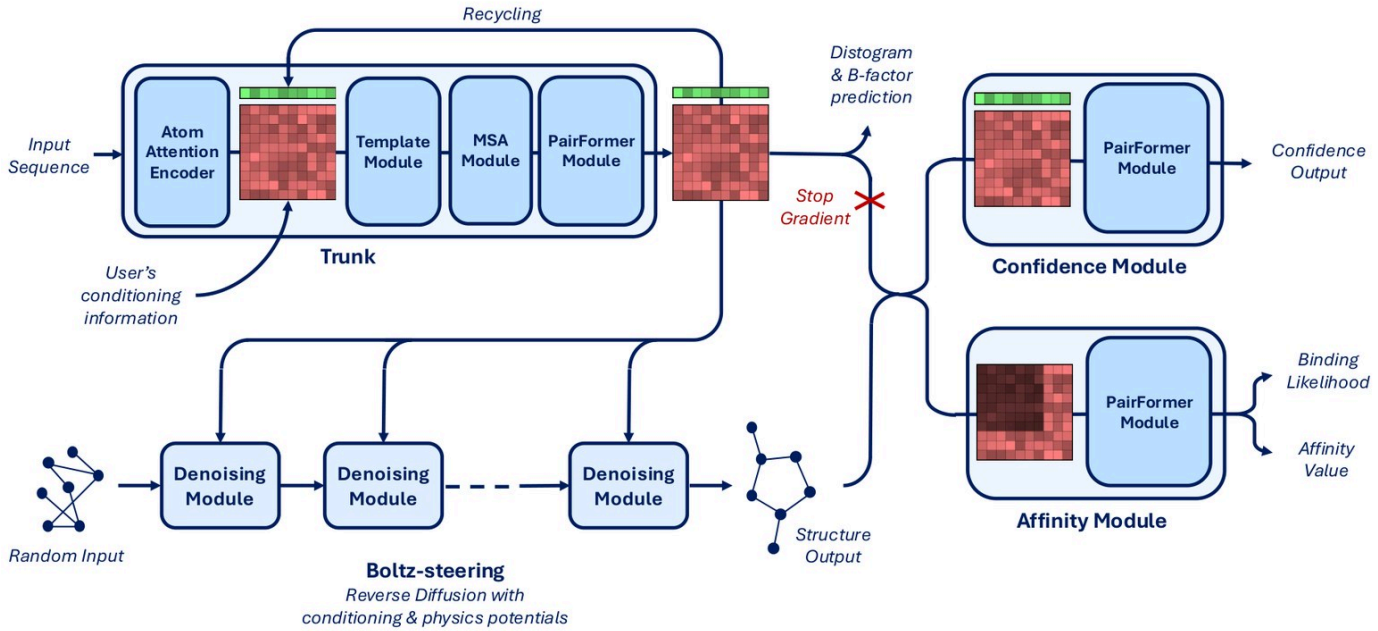
Affinity 예측의 accuracy / speed trade-off
(FEP+ 4-target subset, Fig. 1)

Boltz-2의 목표: 구조 표현과 실험 데이터 학습을 통한 정확도와 계산 시간의 trade-off 개선

Boltz-2의 입력 정보와 모델 구조

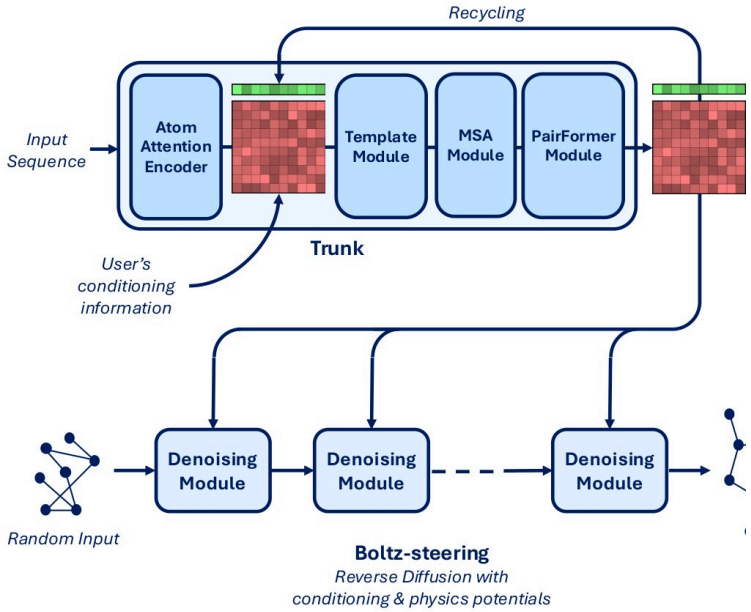
입력 정보

- **기본 입력:** 단백질 서열과 ligand의 원자, 결합 정보
- **Token:** 모델의 처리 단위로, 단백질은 주로 잔기, 작은 분자는 원자에 대응
- **MSA:** 유사 단백질의 서열을 정렬한 자료로, 함께 변하는 잔기 패턴을 구조 예측에 활용
- **Template:** 이미 알려진 유사 단백질, 복합체의 구조를 참고 정보로 활용



Boltz-2 model architecture (Fig. 2)

모델 구조 (1/2): Trunk와 Denoising을 통한 구조 생성



Trunk와 Denoising module (Fig. 2 일부)

초록색 막대 = single representation, **빨간 격자** = pair representation의 도식
빨간 격자의 각 위치는 token 쌍의 관계에 대응하며, 실제 원자 좌표나 거리 행렬 자체는 아님

① Trunk의 정보 처리

단백질 서열과 ligand의 원자, 결합 정보를 모델이 처리할 수 있는 표현으로 변환

1. **Atom Attention Encoder:** 원자 수준의 정보 처리
2. **Template Module:** 알려진 유사 구조의 정보 반영
3. **MSA Module:** 유사 단백질 서열의 정보 반영
4. **PairFormer Module:** Token의 특징과 token 사이의 관계 갱신
5. **Recycling:** 계산한 표현을 다시 Trunk에 넣어 반복적으로 갱신

② Denoising을 통한 좌표 생성

1. 무작위 좌표(Random Input)에서 시작
2. 각 denoising 단계에서 Trunk 표현을 조건으로 사용하여 noise 제거
3. 좌표 갱신을 반복
4. 최종 복합체의 3D 좌표(Structure Output) 출력

여러 박스는 서로 다른 모델을 순서대로 학습한다는 의미가 아니라, denoising 과정의 반복을 표현

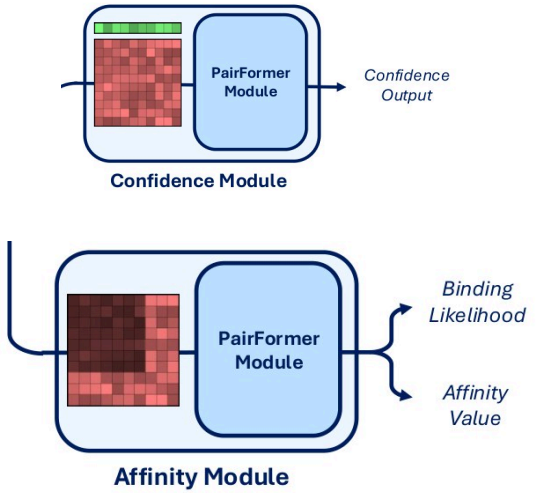
모델 구조 (2/2): Confidence와 Affinity module

③ 구조 평가와 Affinity 예측

생성한 좌표와 Trunk 표현을 두 모듈에서 활용

모듈	출력의 의미	용도
Confidence module	예측 구조의 정확도, 신뢰도	후보 구조 선택
Affinity module	Binding likelihood와 affinity value	결합 후보 선별 및 후보 간 결합 강도 비교

- 두 모듈은 공통의 구조와 표현을 받아 각각 예측
- **Confidence 점수가 affinity 값으로 변환되는 구조는 아님**



Confidence module, Affinity module (Fig. 2 일부)

④ Stop Gradient

- Confidence, affinity module을 학습할 때 그 오차가 Trunk까지 역전파되지 않도록 차단
- Trunk의 정보는 전달하지만, 그 단계의 학습으로 **구조 모델을 수정하지 않음**

Boltz-2의 처리 순서와 학습 순서

모델의 처리 순서

순서	모듈	처리 내용
1	**Trunk**	입력으로부터 각 token의 특징과 token 사이의 관계 계산
2	**Denoising module**	Trunk 표현을 이용하여 원자 좌표의 noise를 제거하고 복합체 구조 생성
3	**Confidence module**	생성된 구조의 정확도와 신뢰도 추정
4	**Affinity module**	Trunk 표현과 예측 구조를 이용하여 결합 가능성, affinity 예측

학습 순서

① Structure training → **② Confidence training** → **③ Affinity training**

- Structure training에서 학습한 표현과 좌표를 이후 단계에서 재사용
- Affinity training에서는 구조 모델로 향하는 **gradient 차단**

Structure training: 복합체 구조 학습 (1/2)

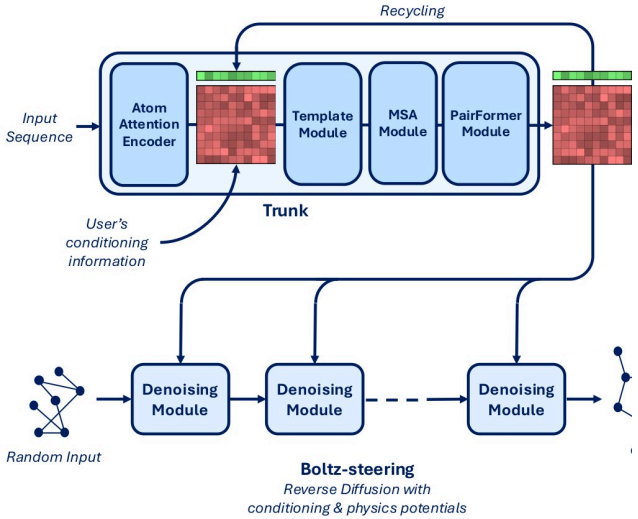
목적: 단백질과 ligand의 결합 위치, 원자 좌표 및 여러 conformation 학습

① 학습에 사용할 구조 준비

- **PDB 실험 구조**, **NMR ensemble**, **MD에서 추출한 구조** 사용
- AlphaFold2, Boltz-1의 고신뢰도 예측 구조를 추가하는 **distillation**으로 부족한 구조 데이터 보충

② Trunk에서 분자와 관계 표현 계산

- 단백질 서열과 ligand 정보, MSA, template을 입력
- **Single representation:** 각 token의 특징 계산
- **Pair representation:** token 쌍의 관계 계산



Trunk와 Denoising module (Fig. 2 일부)

학습 흐름

① 정답 구조 확보 (PDB, NMR, MD + distillation)
② Trunk: 서열과 ligand 정보로 single, pair representation 계산
③ Distogram 학습 (다음 슬라이드): pair representation으로 정답 거리 분포 예측
④ Denoising: noise를 넣은 정답 좌표를 Trunk 표현을 참고해 복원

Structure training: 복합체 구조 학습 (2/2)

③ Trunk의 거리 분포 예측 학습

- 학습 구조의 좌표에서 token 사이의 거리를 계산하여 **distogram 정답** 구성
- Pair representation으로 해당 거리 분포를 예측하도록 학습
- NMR, MD ensemble에서는 여러 구조의 거리 분포를 통합하여 conformation에 따른 거리 변화 반영

④ Denoising module의 좌표 복원 학습

- 학습 구조 하나를 선택하여 원자 좌표에 noise 추가
- **Trunk 표현을 조건으로 원래 좌표를 복원**하도록 학습
- Ensemble에서는 학습마다 하나의 conformation을 sampling하여 다양한 구조 상태 학습
- **그림의 Random Input은 새로운 구조 예측 시의 시작점**이며, 학습에서는 **정답 구조에 noise를 추가한 좌표**를 사용

무작위 좌표 → **Denoising (Trunk 표현 조건) ↻ 반복** → **3D 복합체 구조**

새로운 복합체의 예측: Trunk 표현 계산 후, 무작위 좌표의 noise를 반복적으로 제거하여 3D 구조 생성

Structure training: Protein flexibility와 예측 제어

① 여러 구조를 이용한 변동성 학습

- **MD trajectory:** 시간 순서대로 저장한 시뮬레이션 구조
- **Ensemble:** 동일 시스템이 취할 수 있는 여러 conformation의 집합
- 거리 분포 학습과 좌표 복원 학습에 NMR, MD 구조를 사용하여 구조 다양성 반영

② Single representation의 B-factor 예측 학습

- **B-factor:** 원자 위치의 퍼짐을 나타내며, 열적 움직임과 구조적 무질서 등의 영향을 받는 값
- 실험 B-factor와 MD에서 계산한 값을 정답으로 사용
- Trunk의 single representation으로 token별 B-factor를 예측하여 **국소적인 구조 변동 정보 학습**

③ 예측 시 조건과 물리적 제약 적용

- **Method conditioning:** X-ray, NMR, MD 등 예측 조건 지정
- **Template conditioning:** 유사 복합체의 구조 정보 입력
- **Contact / pocket conditioning:** 알려진 접촉과 결합 부위 정보 입력
- **Boltz-steering:** 구조 생성 중 물리 기반 potential을 적용하여 원자 충돌과 입체화학 오류 감소

Boltz-2x: Physicality steering을 적용한 버전

Confidence training: 구조 신뢰도 추정과 구조 선택

목적: 생성된 구조의 정확도와 예상 오차 추정

① 구조 모델에서 예측 구조 생성

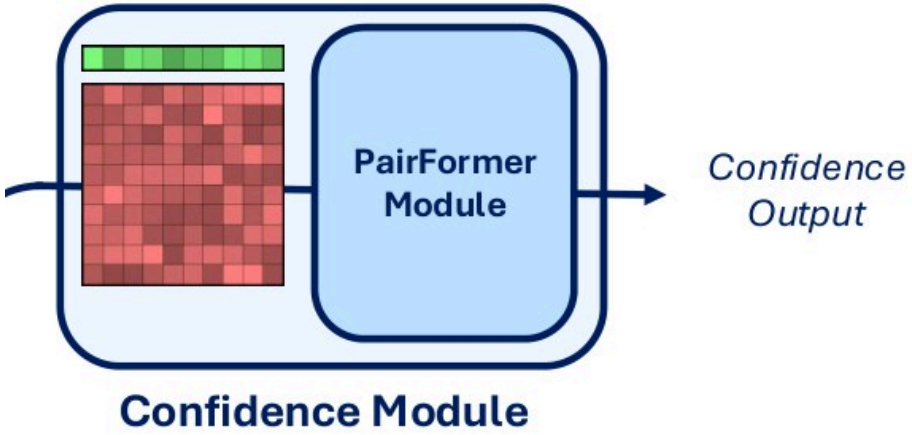
- 학습한 Trunk와 Denoising module을 이용하여 후보 구조 생성

② Confidence module 학습

- Trunk representation과 예측 좌표를 입력
- 예측 구조와 기준 구조를 비교하여 정확도, 오차 계산
- 해당 정확도와 오차를 Confidence module이 예측하도록 학습

③ Affinity 학습에 사용할 구조 선택

- 여러 예측 구조의 **ipTM (interface predicted TM-score)** 계산
- 가장 높은 ipTM의 구조 선택
- 선택한 좌표와 Trunk pair representation을 affinity 학습용으로 저장



Confidence module (Fig. 2 일부)

Confidence와 affinity의 구분: 구조가 정확할 가능성과 실제 결합 강도는 별개의 예측 대상

Affinity training: 결합 여부와 Affinity 학습 (1/2)

① Affinity 학습 데이터 준비

학습 목표	데이터
Binder와 decoy 분류	PubChem HTS, CeMM, MIDAS, synthetic decoys
연속 affinity 예측	PubChem, ChEMBL, BindingDB의 Ki, Kd, IC50 등

- 측정 농도를 μM로 통일한 뒤 $\log_{10}$ 변환
- 낮은 신뢰도 assay, 구조, PAINS, heavy atom 50개 초과 ligand 제외
- HTS에서 화합물 100개 이상, hit rate 10% 미만인 assay 선별

Source	Type	Supervision	# Binders	# Decoys	# Targets	# Compoun
ChEMBL and BindingDB	optimization	values	1.2M (1.45M)	0	2k (2.5k)	600k (700k
PubChem small assays	hit-discovery	both	10k (13k)	50k (70k)	250 (300)	20k (25k)
PubChem HTS	hit-discovery	binary	200k (400k)	1.8M (3.5M)	300 (500)	400k (450k
CeMM Fragments	hit-discovery	binary	25k (45k)	115k (200k)	1.3k (2.5k)	400 (400)
MIDAS Metabolites	hit-discovery	binary	2k (3.5k)	20k (35k)	60 (100)	400 (400)
ChEMBL and BindingDB	synthetic decoys	binary	0	1.2M (1.45M)	2k (2.5k)	600k (700k

Summary statistics of the affinity training dataset (Table 1)

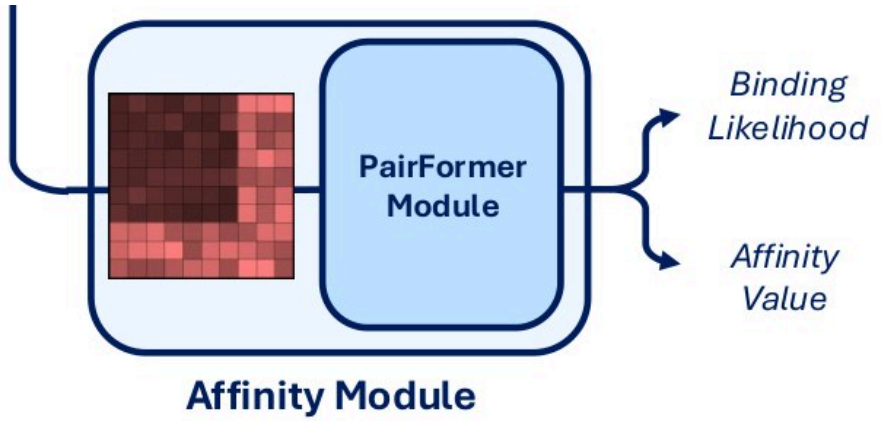
Affinity training: 결합 여부와 Affinity 학습 (2/2)

② 구조 모델의 출력으로 Affinity 입력 구성

- 예측 좌표와 Trunk pair representation을 사전 계산
- Ligand와 pocket 주변을 **최대 256 token, 단백질 최대 200 token**으로 crop
- Pair representation에 입력 특징과 예측 좌표의 거리 정보 결합
- 구조 모델로 향하는 gradient 차단

③ Affinity PairFormer와 두 Head의 예측

- **Affinity PairFormer:** Protein–ligand 및 intra-ligand 상호작용 처리
- 상호작용 표현을 pooling한 뒤 두 head에 전달
- **Binding likelihood:** Binder와 decoy 분류
- **Affinity value:** 연속적인 결합 강도 예측



Affinity module (Fig. 2 일부)

④ 실험 라벨과 비교하여 Affinity module 학습

- 연속값에 **Huber loss**, 이진 분류에 **focal loss** 적용
- 동일 assay의 후보들을 묶어 sampling하고 **후보 간 affinity 차이**를 강조
- 공통적인 assay 조건의 영향과 큰 측정 오차의 영향 완화

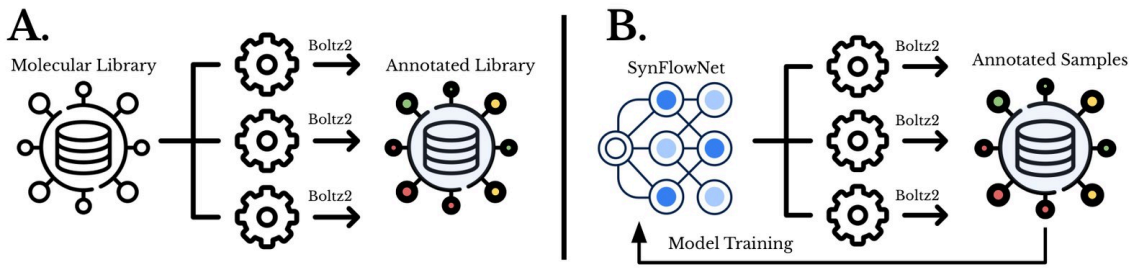
학습된 Affinity module의 활용 방식

Library screening

1. 기존 화합물 library에서 ligand 입력
2. Boltz-2의 binding likelihood와 affinity value 예측
3. 두 예측값을 조합한 screening score 계산
4. 높은 점수의 화합물을 후속 평가 대상으로 선정

De novo generation

1. **SynFlowNet**이 building block과 합성 반응 규칙을 이용하여 후보 분자 구조 생성
2. Boltz-2가 생성 ligand의 표적 단백질 결합 가능성, affinity 평가
3. 두 예측값을 조합한 reward를 replay buffer에 저장
4. Reward를 이용하여 높은 점수의 후보를 생성하도록 SynFlowNet 학습
5. 점수, 품질, 다양성을 고려한 최종 후보 선정



A) Fixed-library virtual screen B) Generative virtual screen (Fig. 9)

두 방식의 차이: 기존 분자 중 후보 선별 / 후보 분자 생성 후 선별

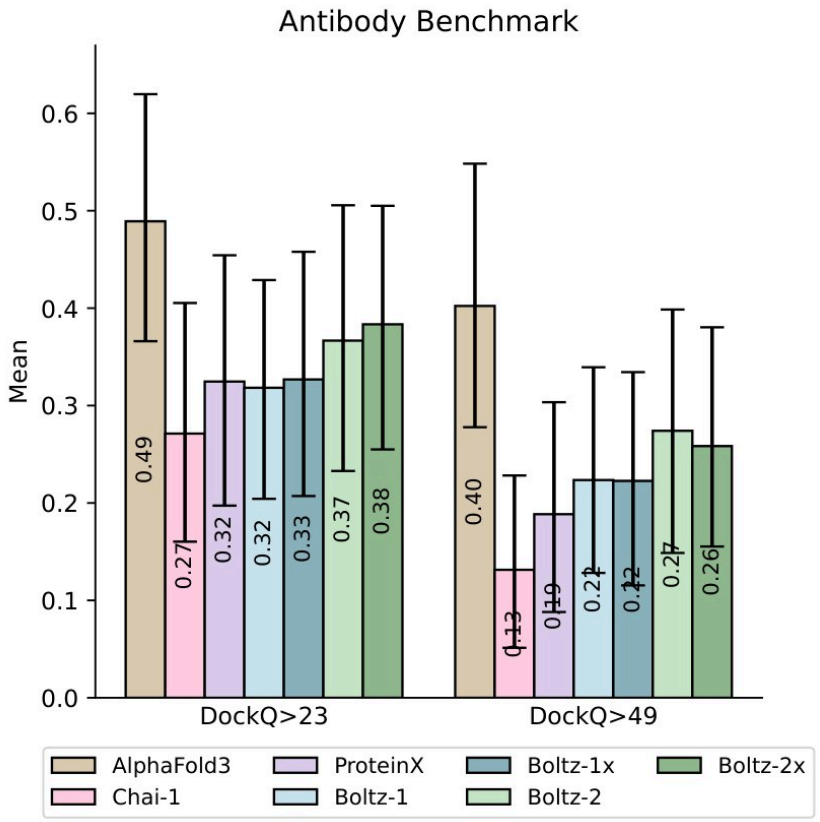
Structure prediction 평가: Complex structure

복합체 구조 예측과 conformational diversity의 평가

- **평가 대상:** 학습에 포함되지 않은 antibody–antigen complex의 binding interface
- **DockQ:** 예측 interface와 실험 구조의 일치도를 나타내는 지표로, **값이 클수록 높은 일치도**
- 표의 수치는 각 DockQ 기준을 초과한 복합체의 비율

성공 기준	Boltz-1	Boltz-2	AlphaFold3
DockQ > 0.23	32%	**37%**	49%
DockQ > 0.49	22%	**27%**	40%

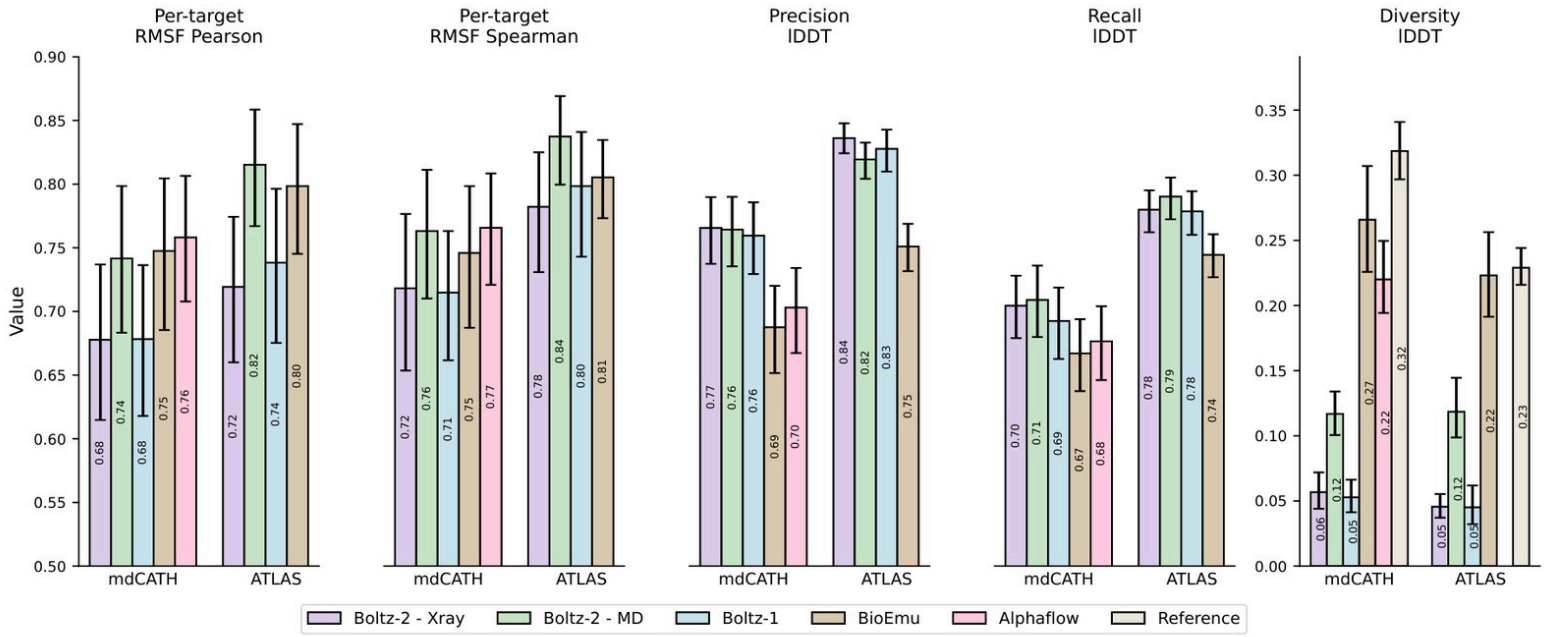
- Boltz-1 대비 두 기준에서 각각 **5%p 개선**
- AlphaFold3 대비 각각 **12%p, 13%p 낮은 성공률**



Antibody benchmark (Fig. 4 left)

Structure prediction 평가: Protein dynamics

- **평가:** MD trajectory의 구조와 Boltz-2의 predicted ensemble 비교
- **RMSF:** 각 원자가 평균 위치에서 벗어나는 fluctuation의 크기
- MD-conditioned Boltz-2의 Boltz-1 대비 RMSF 예측 개선 및 전문 모델과 경쟁력 있는 결과
- **평가 범위:** Fluctuation 크기와 구조 다양성으로 한정하며, 시간 순서와 전환 속도는 평가 대상에서 제외

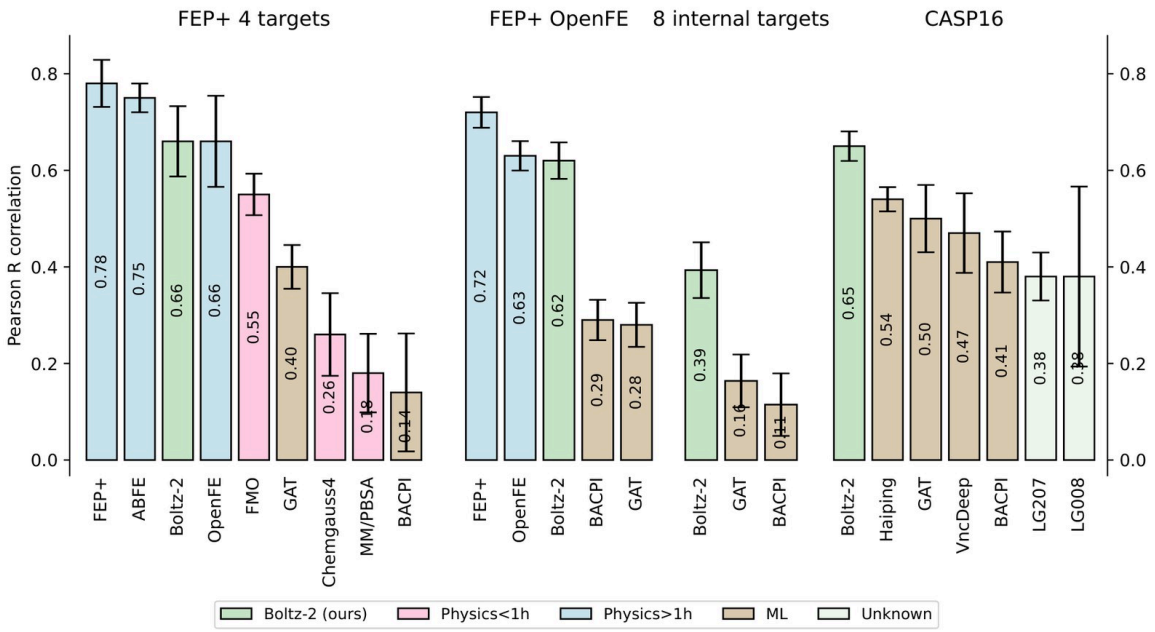


Per-target RMSF correlation과 lDDT (mdCATH / ATLAS held-out clusters, Fig. 5)

Affinity prediction 평가: Hit-to-lead와 Lead optimization

- **평가 대상:** Affinity value와 실험 측정값의 상관
- **Pearson R:** 값이 클수록 실험값의 변화 경향을 잘 반영하는 지표

평가 데이터	Boltz-2	비교 방법
FEP+ 4-target	**0.66**	FEP+ 0.78, OpenFE 0.66
OpenFE subset	**0.62**	OpenFE 0.63
CASP16 affinity track	**0.65**	최고 참가 방법 0.54

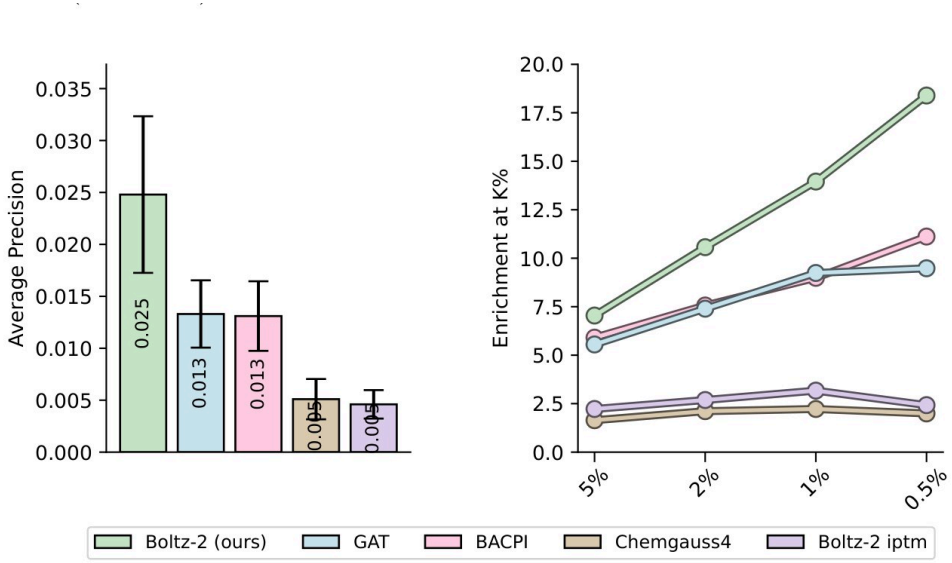


Assay별 평균 Pearson correlation (Fig. 6)

- FEP+ 4-target: **CDK2, TYK2, JNK1, P38**에서 평가
- 해당 비교에서 FEP에 근접한 상관과 **1,000배 이상의 계산 속도 향상** 보고
- CASP16: 두 표적의 **140개 protein–ligand pair**에서 평가

Affinity prediction 평가: Hit discovery

- **평가 대상:** Binding likelihood를 이용한 실제 활성 분자의 상위 순위 배치
- **MF-PCBA:** PubChem screening assay를 활용한 benchmark
- **AP:** Precision–recall 성능을 요약한 지표
  - Boltz-2 **0.025**, 비교 ML 방법 약 **0.013**
- **EF:** 상위 후보의 활성 비율을 전체 데이터의 활성 비율로 나눈 값
  - 상위 0.5%에서 **EF 18.4**, 즉 무작위 선택 대비 **18.4배의 활성 분자 농축**



Left: MF-PCBA average precision Right: top-K% enrichment factor (Fig. 7)

TYK2 후보 탐색 (1/2)

Benchmark에서 평가한 Boltz-2 예측값을 후보 선정에 적용한 사례

- **TYK2:** 면역 신호 전달에 관여하는 kinase 효소이자 후보 탐색 표적

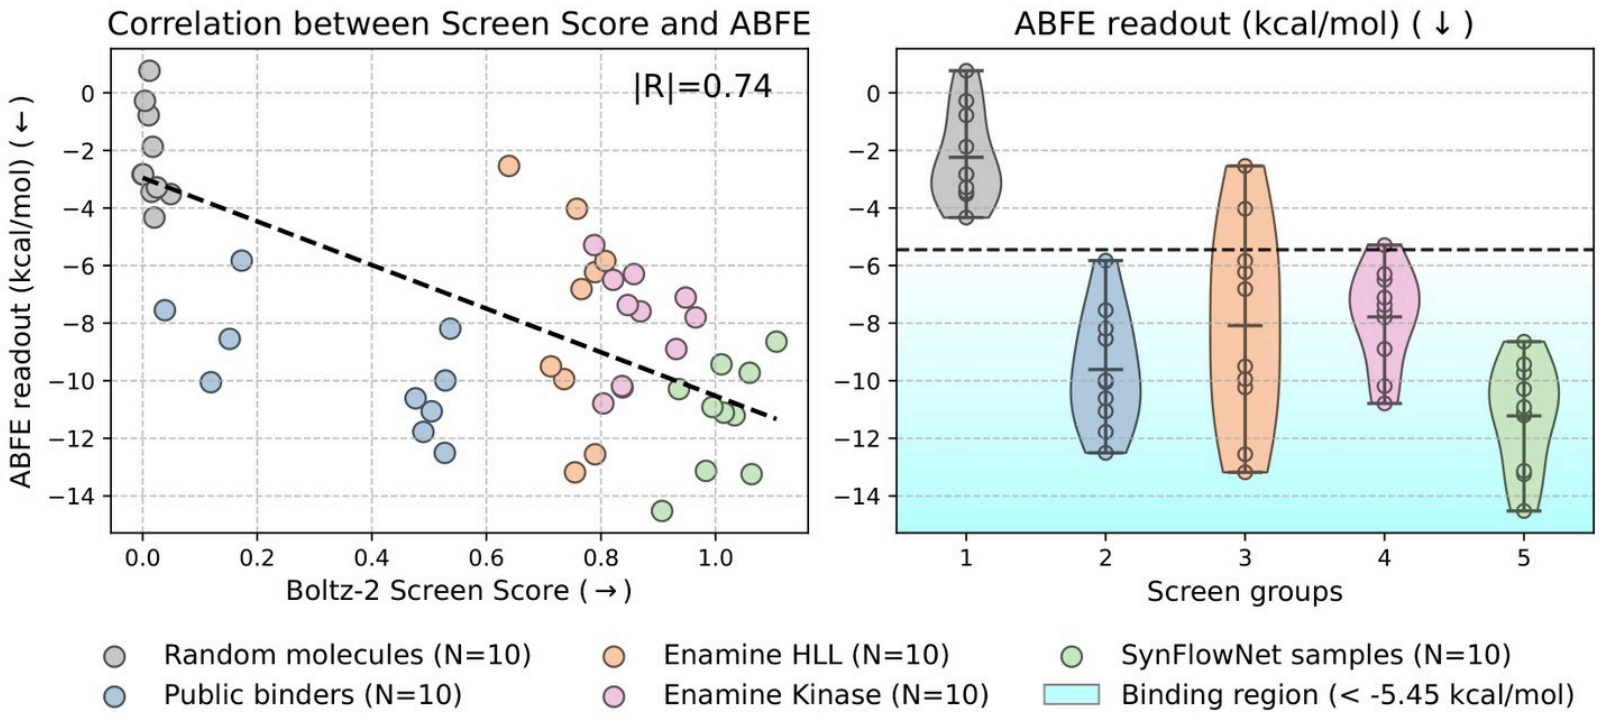
Library screening

1. **Enamine의 두 화합물 library screening**
   - **HLL 460,160개:** 다양한 분자 구조를 포함한 초기 hit 탐색용 화합물 모음
   - **Kinase Library 64,960개:** Kinase 억제제 탐색을 위해 구성한 화합물 모음
2. Binding likelihood와 affinity value를 조합한 점수로 상위 후보 선정
3. 선정 후보의 결합 가능성을 추가 확인하기 위한 **ABFE simulation**
   - **ABFE:** 원자 수준 시뮬레이션을 통한 결합 자유에너지 추정 방법
4. 각 상위 10개 중 **HLL 8개**, **Kinase Library 10개**의 결합 예측

De novo generation

1. SynFlowNet을 이용한 **TYK2 결합 후보 ligand의 분자 구조 생성**
   - Enamine REAL chemical space의 building block과 합성 반응 규칙 활용
2. 생성 ligand의 TYK2 결합 가능성, affinity를 Boltz-2로 평가
3. 점수와 분자 다양성을 고려한 **10개 후보 선정**
4. ABFE 기준 **10개 모두**의 결합 예측

TYK2 후보 탐색 (2/2)



Left: Boltz-2 screen score와 ABFE의 상관 (|R| = 0.74) Right: screening 방식별 ABFE 예측 ΔG 분포 (Fig. 8)

- Screen group: 1 Random, 2 Enamine HLL, 3 Enamine Kinase, 4 Public binders, 5 SynFlowNet

검증 수준: 두 결과 모두 ABFE 기반 계산 평가이며, 합성과 결합 실험을 통한 확인은 미수행

결과 해석의 한계

Structure prediction 오류의 영향

- Affinity module의 입력으로 예측 3D 구조와 Trunk representation 사용
- 잘못된 pocket이나 pose에 따른 affinity 예측 오류 가능성

Pocket crop 바깥 정보의 누락

- 계산량 감소를 위해 ligand와 pocket 주변 단백질 영역을 crop
- Crop 밖의 원거리 상호작용이나 다른 결합 부위 정보의 누락 가능성

주변 결합 요소의 반영 한계

- Ion, water molecule, 다른 protein chain에 의한 결합 안정화
- 해당 요소의 역할에 대한 affinity module의 명시적 모델링 한계
- 주변 요소가 중요한 표적에서의 예측 정확도 저하 가능성

큰 구조 변화와 Assay별 성능 편차

- 제한된 MD 학습 데이터와 큰 conformational change 예측의 한계
- 내부 assay 8개 중 **3개에서 Pearson R > 0.55**, 나머지 **5개에서 제한적인 성능**

결론: Boltz-2를 활용한 빠른 후보 우선순위 설정과, 선정 후보에 대한 구조 검토, 실험 검증의 필요성

References

1. S. Passaro, G. Corso, J. Wohlwend, M. Reveiz, S. Thaler, V. Ram Somnath, N. Getz, T. Portnoi, J. Roy, H. Stark, D. Kwabi-Addo, D. Beaini, T. Jaakkola, and R. Barzilay, *Boltz-2: Towards Accurate and Efficient Binding Affinity Prediction*, bioRxiv, doi:10.1101/2025.06.14.659707, 2025.
2. J. Wohlwend, G. Corso, S. Passaro, et al., *Boltz-1: Democratizing Biomolecular Interaction Modeling*, bioRxiv, 2024.
3. J. Abramson, J. Adler, J. Dunger, et al., *Accurate structure prediction of biomolecular interactions with AlphaFold 3*, Nature, 630:493–500, 2024.
4. M. Cretu, C. Harris, I. Igashov, et al., *SynFlowNet: Design of Diverse and Novel Molecules with Synthesis Constraints*, arXiv:2405.01155, 2024.
5. G. A. Ross, C. Lu, G. Scarabelli, et al., *The maximal and current accuracy of rigorous protein-ligand binding free energy calculations*, Communications Chemistry, 6:222, 2023.

Thanks!