abstain-dti · W02 논문 리뷰 · 2026.10.17

단백질 언어모델은 구조를 어떻게 배우나

구조생물학자가 AI 팀에게: 아미노산 한 글자에서 "모델의 자기 확신"까지

Lin et al., Evolutionary-scale prediction of atomic-level protein structure with a language model. Science 379:1123–1130 (2023)

발표: 이성주 · 큐레이션 트랙

왜 이 논문인가

ESM-2는 조건 A baseline이 단백질을 읽는 방식입니다

입력

단백질 서열 + 화합물 SMILES만. 타겟 ID는 주지 않음

조건 A

서열 → ESM-2 임베딩, 분자 → Morgan fingerprint, + AlphaFold pocket feature → XGBoost → conformal

오늘의 질문

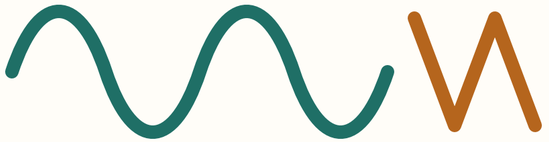
ESM-2의 자기 확신(pLDDT, perplexity)은 실제 난이도를 따라가는가? 그 보정은 결합 예측에도 통하는가?

서열이 정해지면 접히는 모양도 대부분 정해집니다



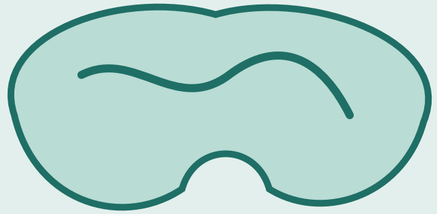
1차 구조

아미노산이 이어진 순서 그 자체. 모델의 입력



2차 구조

이웃끼리 수소결합으로 만드는 국소 무늬: α-나선(청록), β-병풍(주황)



3차 구조

한 사슬 전체가 접힌 3D 모양. 구조 예측의 출력

"서열 안에 접힘 정보가 들어 있다"(Anfinsen)는 것이 구조 예측의 전제입니다. AI 말로는 **서열 → 3D 좌표**라는 함수가 존재하니 학습해 볼 수 있다는 뜻입니다.

기초 2 · 진화가 남긴 힌트

3D에서 맞닿은 두 잔기는 함께 변합니다

같은 단백질의 여러 종 버전을 줄 맞춘 표 = MSA

M	K	L	V	E	A	G	R	D	T
M	K	L	I	E	S	G	R	D	T
M	R	L	V	D	A	G	K	N	T
M	K	I	V	D	A	A	K	D	S
M	K	L	V	K	A	G	E	D	T

예시 서열. 5번(주황)과 8번(청록) 자리가 짝지어 바뀜

왜 함께 변하나

5번과 8번은 서열에선 떨어져 있어도 접히면 맞닿아 +/− 전하로 붙어 있습니다. 한쪽이 바뀌면 다른 쪽도 바뀌어야 구조가 유지되고, 아니면 그 개체는 도태됩니다

접촉 지도

모든 잔기 쌍(L×L)에 대해 "3D에서 Cα 거리 8 Å 안인가"를 표시한 행렬. 3D 구조의 저해상도 요약입니다

AI 말로 바꾸면

열과 열 사이의 동시 출현 통계가 곧 3D 접촉 신호입니다

ESM-2 · Lin et al., Science 2023 · abstain-dti W02 · 4 · 접촉 정의: 논문 Appendix A.2.1

AlphaFold2는 오픈북, ESM-2는 외운 채로 시험을 봅니다

AlphaFold2

입력: 서열 + 시험 때마다 DB에서 검색한 친척 서열(MSA) + 비슷한 구조(템플릿)

AI로 치면: 검색 증강(retrieval-augmented) 모델

장단점: 친척이 많으면 매우 정확. 검색에 시간이 걸리고, 친척이 없으면 약해짐

ESM-2 / ESMFold

입력: 서열 하나. 수천만 개 서열로 미리 학습해 공진화 패턴을 가중치에 저장

AI로 치면: 파라미터 안의 기억(parametric memory)

장단점: 검색이 없어 빠름. 기억에 없는 단백질이라면?

그래서 오늘의 질문: **기억에 없는 단백질 앞에서, 모델은 자기가 모른다는 걸 알까?**

정답과 비교한 점수, 그리고 모델이 스스로 매긴 점수

채점: 정답 구조가 있어야 계산

RMSD (Å) 원자 위치의 평균 거리 오차. 낮을수록 좋음

TM-score (0–1) 전체 접힘이 겹치는 정도. 0.5 이상이면 fold를 맞힘

LDDT (0–1) 각 잔기 주변 거리가 보존된 정도. 국소 정확도

둘이 맞나?

확신: 정답 없이 모델이 출력

pLDDT 모델이 예측한 LDDT. 잔기마다 붙는 자기 확신 점수

PAE 잔기 쌍의 상대 위치 예상 오차. 도메인 배치 신뢰도

pTM 모델이 예측한 TM-score

AI 말로는 분류기의 softmax 확률과 실제 정답률을 비교하는 **보정(calibration)** 문제와 같습니다. 여기서부터가 우리 프로젝트의 질문입니다.

논문 한 장 요약

가려진 아미노산을 맞히도록 학습시켰더니, 모델 안에 단백질 구조가 생겼습니다

15B

가장 큰 ESM-2 모델 (파라미터 150억 개)

최대 60배

AlphaFold2보다 빠름. MSA 검색이 필요 없음

6.17억

2주 만에 구조를 예측한 메타게놈 단백질 수

ESM-2 · Lin et al., Science 2023 · abstain-dti W02 · 7 · M = 백만, B = 십억

ESM-2는 빈칸 채우기로 공진화를 배웁니다

1 · 데이터

UniRef 서열
약 6,500만 개
(라벨 없음)

→

2 · 학습

서열의 15%를 가리고
맞히기 (masked LM)

→

3 · 창발

함께 변하는 잔기 쌍을
익히면서 attention에
contact map이 생김

→

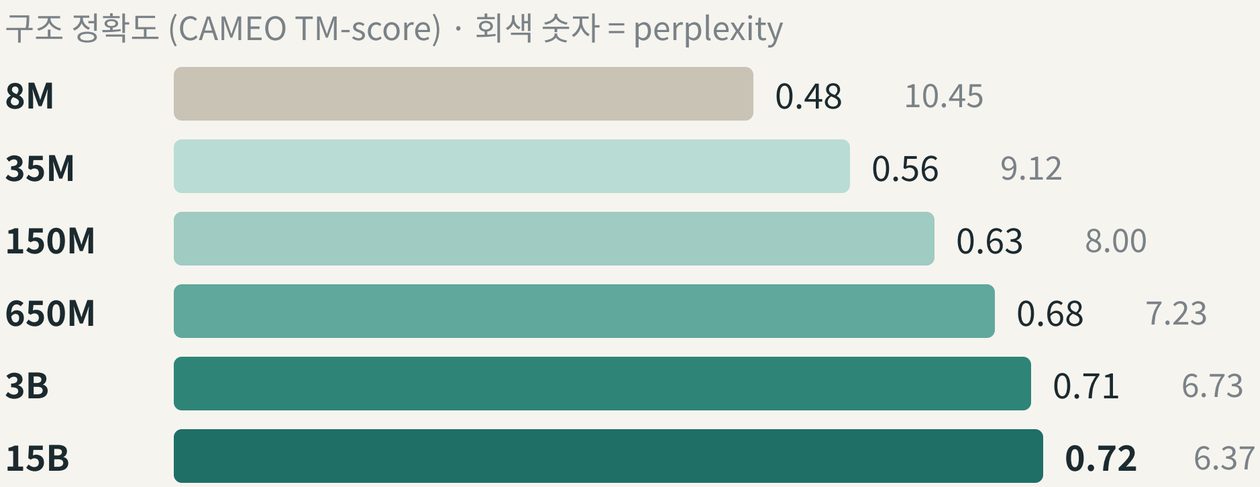
4 · ESMFold

folding head가
3D 구조와
pLDDT를 출력

공진화를 따로 계산해 주지 않아도, 빈칸을 잘 맞히려면 모델이 **어떤 위치들이 함께 변하는지** 스스로 배워야 합니다. 그 결과가 attention 안의 contact map입니다.

Fig. 1 · Table S1 · 모델 크기

모델이 클수록 서열을 더 잘 알고, 구조도 더 잘 맞힙니다



perplexity란?

모델이 아미노산 몇 개 중에서 고민하는지. 1이면 완벽, 20이면 찍기 수준

둘은 함께 움직인다

모델 크기별로 보면 perplexity와 TM-score의 상관이 −0.99~−1.00

친척이 적은 단백질일수록 이득

학습 데이터에 비슷한 서열이 적은 단백질은 15B까지 계속 좋아짐 (Fig. 1B–C)

ESM-2 · Lin et al., Science 2023 · abstain-dti W02 · 9 · M = 백만, B = 십억 (파라미터 수) · 학습 270K 스텝 기준

Fig. 1F · 두 가지 사례

구조는 어느 크기에서 갑자기 맞기 시작하고, 확신도 함께 오릅니다

모델 크기	7QQA 오차 (Å)	7QQA pLDDT	T1056 오차 (Å)	T1056 pLDDT
8M	7.7	59.7	4.4	57.2
35M	7.0	65.6	3.9	61.8
150M	**3.2**	69.9	4.5	59.7
650M	2.9	75.0	4.3	67.1
3B	2.8	75.8	4.0	66.5
15B	2.6	75.6	**2.7**	**75.8**

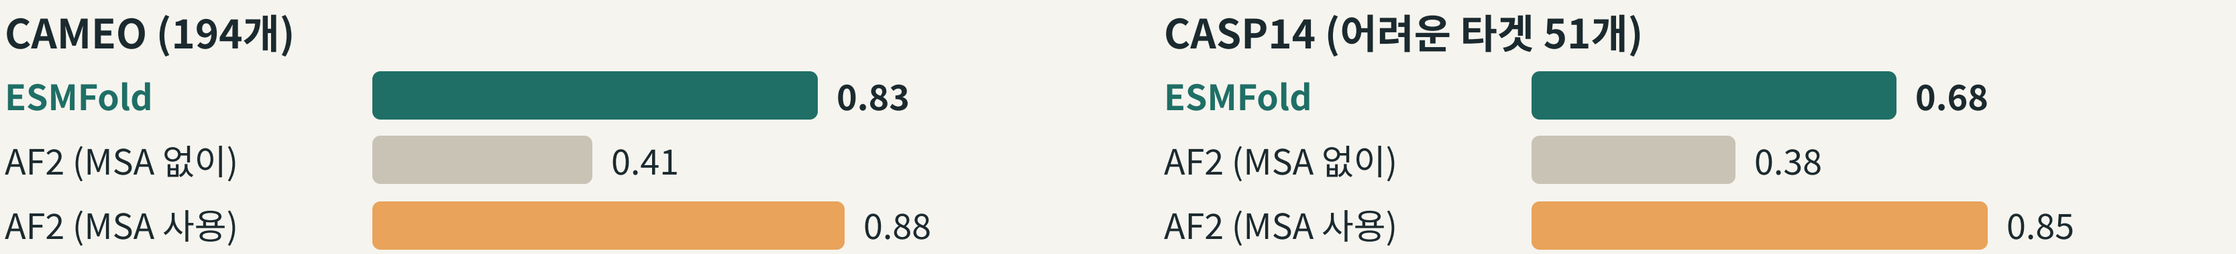
쉬운 타겟 (7QQA): 150M에서 오차가 절반으로 줄고, 그 뒤로는 거의 그대로

어려운 타겟 (T1056): 4 Å 근처에 머물다 15B에서야 크게 개선

ESM-2 · Lin et al., Science 2023 · abstain-dti W02 · 10 · 오차 = RMSD, 낮을수록 좋음 · 수치는 Fig. 1F에서 읽은 값

Fig. 2B · 정확도

MSA가 없으면 AF2는 반토막, ESMFold는 거의 그대로



핵심

AF2가 MSA에서 얻는 정보를 ESMFold는 언어모델에서 얻습니다

단, 어려운 타겟에서는

MSA를 쓴 AF2가 여전히 앞섭니다 (0.85 대 0.68). 주로 perplexity가 높은 단백질

ESM-2 · Lin et al., Science 2023 · abstain-dti W02 · 11 · TM-score 0–1, 높을수록 좋음 · RoseTTAFold도 같은 경향

Fig. 2C · Fig. S5 · 확신도

ESMFold는 자기가 틀릴 때를 대체로 압니다

0.86–0.96

모델의 확신(pLDDT)과 실제 정확도의 상관

1.42 Å

pLDDT가 0.9를 넘을 때의 일반적인 오차. 실험 구조에 가까운 수준

신호 ① 예측한 뒤: pLDDT

점수가 낮은 부분은 믿지 말라는 뜻

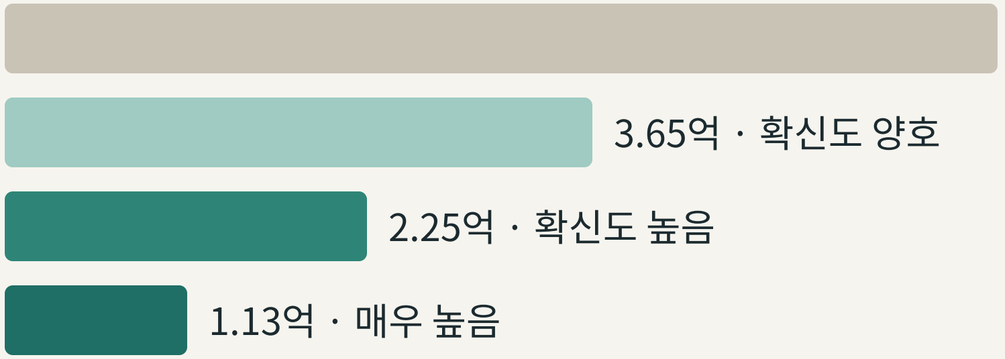
신호 ② 예측하기 전: perplexity

서열만 보고도 어려운 단백질인지 알 수 있음

ESM-2 · Lin et al., Science 2023 · abstain-dti W02 · 12 · 0.86 = CAMEO, 0.96 = CASP14

Fig. 3 · ESM Metagenomic Atlas

6억 개를 예측하고, 확신도로 믿을 만한 것을 골라냈습니다



기준: pLDDT·pTM 0.5 초과 / 0.7 초과, pLDDT 0.9 초과

확신도 높은 구조 100만 개를 보면

12.6%

PDB에 비슷한 구조가 없음

76.8%

알려진 서열과 다름 (identity 90% 미만)

ESM-2 · Lin et al., Science 2023 · abstain-dti W02 · 13 · 막대 길이는 개수에 비례 · GPU 약 2,000대로 2주

이 논문이 보여주지 않은 것

보정은 좋았지만, 그 범위는 논문 안에 정해져 있습니다

단일 사슬로만 학습 (부록 A.1.2)
복합체도 사슬 하나씩만 사용. pLDDT는 리간드·파트너 없는 상태의 확신

어려운 문제의 표본이 작음 (Table S4)
CAMEO hard는 8개. 메타게놈 보정은 실험이 아닌 AF2와의 일치 (Fig. 3A)

친척 없는 단백질은 여전히 어려움 (Fig. S8)
orphan 단백질에서 AF2보다 조금 낮고 편차가 큼. 일부는 크게 틀림

"처음 보는" 기준 (부록 A.1.1)
ESM-2는 UniRef50(2021-09)으로 사전학습. 평가는 구조 기준 2020-05 이후

그래서 남는 질문

구조에 대한 확신이 약물 결합에 대한 확신으로도 이어질까?

이 논문은 재지 않았습니다. 처음 보는 타겟에서, 결합 예측의 확신을 재는 것이 우리 벤치마크입니다

토론 질문

W04 동결 전에 정해야 할 세 가지

1

pocket pLDDT 구간 경계

전체 pLDDT 관례(90/70/50)를 pocket에도 그대로 쓸까? P2Rank가 고른 pocket이 실제 결합 부위인지는 누가 검수할까?

2

ESM-2 크기 선택

650M(1280차원)이 흔한 선택. CPU로 BindingDB 타겟 전체 임베딩이 가능한지 W05 전에 확인

3

7번째 좌표 후보: perplexity

타겟 서열의 ESM-2 pseudo-perplexity를 좌표나 공변량으로? 단, PLM 우도엔 종 편향이 있음 (Ding & Steinhardt)

abstain-dti · W03 과제 발표 · 2026.10.24

BindingDB와 AlphaFold DB, 직접 열어보기

SMILES · 단백질 서열 · 결합 친화도는 어떻게 한 줄로 묶이나

과제: ① 두 DB의 구조와 활용법 (LLM 활용) ② 직접 다운로드해 구성 확인
③ SMILES–서열–친화도 관계, 쓸 수 있는 데이터셋과 메타데이터

발표: 이성주 · 큐레이션 트랙

한 장 요약

데이터는 충분히 크지만, 그대로 쓰면 세 군데서 넘어집니다

17.6%

검열값

">10,000 nM"처럼 정확한 값이 아닌 측정. 숫자로 바꾸면 가짜 정답이 됨

18.5%

반복 측정 노이즈

같은 화합물·타겟·측정 종류인데 값이 10배 넘게 다른 쌍의 비율

98%

타겟 누수

공개 BindingDB 벤치마크의 test 타겟이 train에도 있는 비율. cold split이 아님

AlphaFold DB는 BindingDB의 **UniProt ID**로 바로 이어집니다. 다만 BindingDB 서열이 UniProt 전체 서열과 같은지 확인해야 합니다.

abstain-dti W03 · 17.6%, 18.5%: BindingDB 2015-10 처리본 73만 건 · 98%: MolTrans BindingDB 세트 · 2

지난주(W02)와 이어서

ESM-2는 서열, AlphaFold DB는 구조, BindingDB는 정답

단백질 서열 → ESM-2 (W02)
임베딩 1,280차원 (650M)

단백질 구조 → AlphaFold DB (W03)
pocket pLDDT

화합물 SMILES
Morgan fingerprint

→

BindingDB (W03)

친화도 라벨

(화합물, UniProt, 측정 종류)별 pAffinity

→

조건 A

XGBoost → conformal 기권

MSA가 필요 없어서 전부 돌릴 수 있음

단, BindingDB 서열의 12%가 ESM-2 입력 한도(1,022잔기)를 넘음 → 자르기 규칙 필요

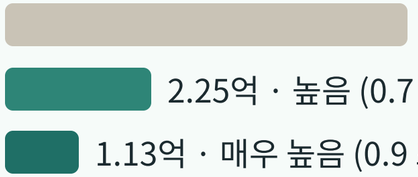
perplexity = 타겟이 얼마나 낯선가

낮을수록 구조 예측이 잘 맞음 (음의 상관). BindingDB 타겟마다 계산하면 난이도 좌표 후보

abstain-dti W03 · 12%: MolTrans BindingDB 세트 고유 서열 1,254개 기준 직접 계산 · 3

예측 구조 DB는 모두 확신도로 걸러서 씁니다

ESM Atlas (W02 논문)



AlphaFold DB (W03)

2.41억 개, 잔기마다 pLDDT (0–100). 파일의 B-factor 칸에 들어 있음

관례: 90 초과 매우 높음, 70 초과 높음, 50 미만 매우 낮음

우리 벤치마크

단백질 전체가 아니라 pocket 잔기의 pLDDT 평균 → "구조 신뢰도" 좌표

신규성도 두 축으로 잰다

ESM Atlas: 구조 신규 12.6%, 서열 신규 76.8% (100만 개 샘플). 우리 split도 서열 유사도 기준

공통 한계

둘 다 단일 사슬, 리간드 없는 상태(apo). 높은 pLDDT가 결합 자세까지 보장하진 않음

기본 단위

DTI 데이터 한 줄 = 누가, 누구에게, 얼마나, 어떤 조건에서

누가 · 화합물
SMILES
InChIKey

→

누구에게 · 단백질
서열
UniProt ID

→

얼마나 · 친화도
Ki · Kd · IC50 · EC50
(nM, 부호 포함)

→

어떤 조건 · 출처
pH, 온도
논문·특허, 날짜

친화도는 쌍의 성질이 아니라 실험의 결과

같은 화합물–단백질 쌍도 측정 종류와 조건이 다르면 값이 달라집니다

AI 말로 바꾸면

입력 두 개(SMILES, 서열), 라벨 하나(pAffinity). 라벨에는 측정 방식이라는 숨은 변수가 붙어 있습니다

BindingDB 한눈에

실험으로 잰 결합값 325만 건을 무료로 받을 수 있습니다

325만
측정값 (3,248,380건)

145만
화합물 (1,446,269개)

1.15만
타겟 (11,516개)

받을 파일	크기	쓰임
BindingDB_All_202610_tsv.zip	567 MB	전체 측정값. 우리가 쓸 주 파일
BindingDBTargetSequences.fasta	7 MB	모든 타겟 서열 (ESM-2 입력)
BindingDB_UniProt.txt	0.6 MB	BindingDB 단백질 → UniProt ID
출처별 부분 파일 (ChEMBL, 특허, 논문 등)	0.1–329 MB	출처를 나눠 보고 싶을 때

BindingDB TSV 구조

640열이지만, 필요한 건 다섯 묶음뿐입니다

① 화합물

Ligand SMILES · InChI Key · MonomerID · PubChem / ChEMBL / DrugBank ID

② 측정값

Ki · IC50 · Kd · EC50 (nM), kon · koff. 한 행에 보통 하나만 채워짐

③ 조건

pH · Temp (C). 대부분 비어 있음

④ 출처

Curation/DataSource · DOI · PMID · 특허번호 · 발표일 · BindingDB 등록일

⑤ 타겟 사슬 (최대 50개 × 12열)

사슬 수 · 사슬 서열 · 사슬별 PDB ID · UniProt 이름과 Primary ID. 사슬 수가 2 이상이면 복합체

직접 열어본 첫 행: 특허 출처, IC50 4,440 nM, 사슬 2개 (MyD88 펩타이드 + MAPK3). **"타겟 하나 = 서열 하나"라고 가정하면 이런 행에서 틀립니다.**

측정값 네 종류

Ki·Kd는 결합 세기, IC50·EC50은 조건 따라 바뀌는 효과

종류	뜻	비교할 때 주의
Kd	결합한 복합체가 절반 해리되는 농도	가장 직접적인 결합 세기
Ki	저해제가 효소에 붙는 세기 (해리 상수)	Kd와 같은 성격. 서로 비교 가능한 편
IC50	활성을 50% 막는 농도	기질 농도에 따라 값이 바뀜 (Ki = IC50 ÷ (1 + [S]/Km), 경쟁적 저해일 때)
EC50	효과가 50% 나타나는 농도	결합이 아니라 기능 반응. 결합 세트에선 보통 제외

모델에 넣는 형태: pAffinity

p값 = 9 − log10(nM). 1 nM → 9, 1 μM → 6, 10 μM → 5. 1 차이 = 10 배

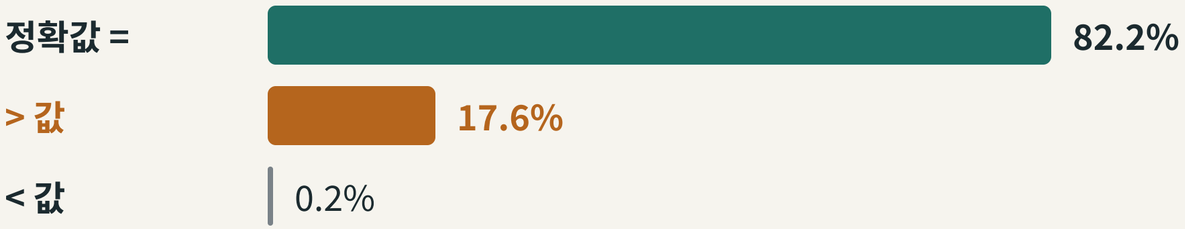
그래서

pKi와 pIC50을 한 열에 섞으면 측정 방식 차이가 라벨 노이즈가 됩니다. 섞을 거면 측정 종류를 feature로 남겨야 합니다

직접 열어보니 ① · 검열값

">10,000 nM"은 "이 농도까진 안 붙었다"는 뜻입니다

BindingDB 2015-10 처리본, 측정값 부호 (73만 4,737건)



가장 흔한 단일 값은 ">10,000 nM" (5만 4,467건). Kd는 중앙값이 pKd 5.0, 즉 검열선에 걸려 있음

69.6%

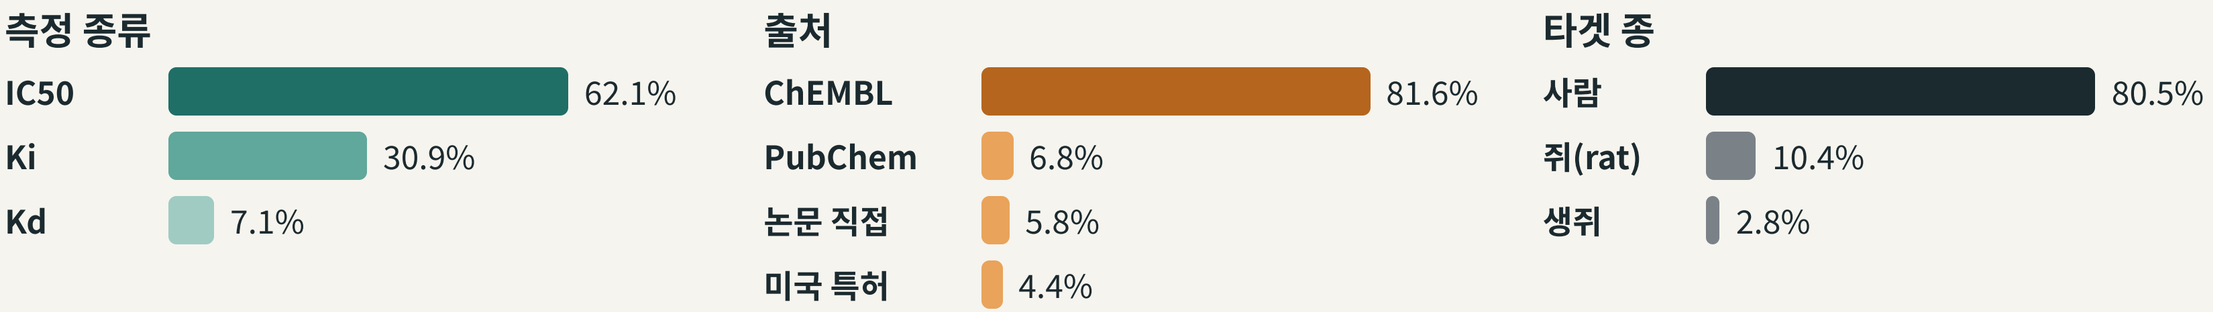
Davis 세트(68 화합물 × 442 키나아제)에서 값이 정확히 10,000 nM인 칸. "안 붙음"을 pKd 5로 채운 것

우리 프로젝트에 주는 뜻

회귀 라벨로 쓰면 모델이 "5.0"을 외웁니다. 검열값은 분류(붙음/안 붙음)에 쓰거나 따로 표시해야 합니다

직접 열어보니 ② · 무엇이 얼마나 들어 있나

IC50이 대부분이고, 출처는 ChEMBL, 종은 사람이 압도적입니다



숫자로: 측정 73만 건에 화합물 33.7만 개, 타겟(UniProt) 3,156개. 화합물이 타겟보다 100배 많음

주의: 사람과 쥐 단백질은 서열이 거의 같아도 다른 타겟. split을 UniProt ID로만 나누면 사실상 같은 단백질이 양쪽에 들어갈 수 있음

직접 열어보니 ③ · 쏠림과 노이즈

타겟 대부분은 데이터가 적고, 같은 쌍도 다시 재면 값이 흔들립니다

31건

타겟 하나당 측정 수의 중앙값

31%

측정이 10건도 안 되는 타겟의 비율

18.5%

두 번 이상 잰 쌍 8.5만 개 중 값이 10배 넘게 다른 쌍

데이터가 적은 타겟 = 처음 보는 타겟에 가까움

우리 "타겟 신규성" 좌표를 측정 수로도 볼 수 있다는 뜻

실험 노이즈가 정확도의 천장

재측정 값이 1 log 단위씩 흔들리면 모델 오차도 그 아래로 내려가기 어려움

AlphaFold DB 한눈에

UniProt ID 하나로 예측 구조와 확신도를 받습니다

2.41억

예측 구조 수 (v6, 2025-10). UniProt 2025_03에 맞춤

파일	들어 있는 것
model .cif / .pdb	3D 좌표. **B-factor 열 = 잔기별 pLDDT (0–100)**
predicted_aligned_error .json	PAE 행렬: 잔기 쌍의 상대 위치 오차
confidence .json	잔기별 pLDDT 목록

받는 법

API: /api/prediction/{UniProt} → 파일 URL. 대량: 종별 proteome 묶음, FTP, Google Cloud

v6에서 바뀐 것

API 필드 이름이 바뀌고 옛 필드는 2026-06-25 종료. 코드에 v4 이름을 박아 두면 깨짐

한계

단일 사슬, 리간드 없는 상태(apo). pocket 모양은 결합 상태와 다를 수 있음

두 DB 잇기

UniProt ID가 다리지만, 서열이 같은지는 따로 확인해야 합니다

BindingDB 행
UniProt Primary ID
+ 실험에 쓴 서열

→

AlphaFold API
AF-{UniProt}-F1
전체 길이 서열

→

pocket 찾기
P2Rank 등
→ 잔기 번호

→

좌표
pocket pLDDT
평균

어긋나는 경우	확인 방법
도메인만 쓴 실험	BindingDB 서열이 UniProt 서열의 일부 구간인지 정렬로 확인 (키나아제 도메인 등)
돌연변이 · 태그	같은 UniProt인데 서열이 몇 글자 다름 → 돌연변이 타겟으로 따로 표시
복합체 타겟	사슬 수 2 이상 → AlphaFold 단일 사슬과 맞지 않음. 처음엔 제외
아주 긴 단백질	여러 조각(F1, F2…)으로 나뉜 항목이 있음 → 조각 번호 확인

활용 가능한 데이터셋

크기보다 라벨 형태와 나누는 방식이 먼저입니다

데이터셋	크기 (쌍)	라벨	특징 · 주의
BindingDB 전체	3,248,380	Ki/Kd/IC50/EC50 nM	원본. 정제는 우리 몫. 출처·날짜 메타데이터가 가장 풍부
TDC BindingDB_IC50	991,486	IC50 nM	BindingDB 2020-02판을 측정 종류별로 나눈 것
TDC BindingDB_Ki	375,032	Ki nM	같은 출처. cold drug / cold target split 제공
TDC BindingDB_Kd	52,284	Kd nM	가장 작지만 결합 세기에 가장 직접적
Davis	30,056	Kd nM	68 화합물 × 442 키나아제 전부 측정. 70%가 10 μM 검열값
KIBA	118,036	KIBA 점수	Ki·Kd·IC50을 합친 점수. 단위 없음
MolTrans BindingDB	32,601	결합 1 / 0	이진 분류용. 다음 장: test 타겟 98%가 train에 있음

우리 선택 제안: BindingDB 전체에서 직접 정제 → 메타데이터(출처, 날짜, 측정 종류)를 지키고 cold-target split을 우리 기준으로 만들 수 있음. TDC 세트는 결과 비교용

직접 열어보니 ④ · 벤치마크 함정

공개 세트의 test는 대부분 "이미 본 타겟"입니다

MolTrans BindingDB test 13,289쌍 중



라벨 비율도 train은 50:50, test는 결합 14.3%로 다름

이게 왜 문제인가

모델이 "이 타겟은 원래 잘 붙는다"는 타겟별 평균만 외워도 점수가 높게 나옵니다

우리 벤치마크는

test 타겟을 train에서 완전히 빼는 cold-target split. 가능하면 서열 유사도로 묶어서

제안 · 우리 정제 규칙 초안

W04 동결 전에 정할 정제 규칙 일곱 가지

1 · 사람, 단일 사슬
복합체와 다른 종은 처음엔 제외

2 · 측정 종류 분리
Ki·Kd 중심. IC50은 별도 세트, EC50은 제외

3 · 검열값 분리
회귀는 정확값만. ">" 값은 비결합 라벨로 분류에만

4 · 중복은 중앙값
(InChIKey, UniProt, 측정 종류)별 중앙값. 범위가 1 log 넘으면 표시

5 · 메타데이터 보존
출처, 발표일, pH·온도, 복합체 PDB ID

6 · cold-target split
UniProt가 아니라 서열 유사도 클러스터로 나눔

7 · 구조 연결 확인
BindingDB 서열과 AlphaFold 서열을 정렬해 구간을 맞춘 뒤 pocket pLDDT 계산

LLM 활용 후기

LLM은 지도를 빨리 그려 주지만, 길은 파일로 확인해야 합니다

잘 된 것

헤더 한 줄을 주고 "열을 묶어서 설명해 줘" → 640열을 다섯 묶음으로 정리

"검열값, 복합체, 중복을 처리하는 파서를 짜 줘" → 분석 스크립트 초안

Ki·IC50 차이처럼 개념 설명

조심할 것

열 이름이 판마다 다름 (2015판은 "Chain Sequence"에 공백 두 칸)

AlphaFold API 필드가 v6에서 바뀜. 학습 시점 지식으로 짠 코드는 깨질 수 있음

숫자(데이터 크기 등)는 공식 페이지에서 다시 확인

바로 써먹는 프롬프트

"아래는 BindingDB TSV의 헤더와 첫 5행이다. 각 열의 뜻, 빈 값 비율, DTI 학습에 쓸 때의 함정을 표로 정리하고, 확실하지 않은 건 확실하지 않다고 표시해 줘."

다음 할 일

스크립트 하나로 최신판에서 같은 숫자를 다시 뽑습니다

1

2026-10 전체 TSV로 재집계

Colab에서 스크립트 실행 → summary.json, clean_pairs.csv. 2015판과 비교

2

상위 타겟 AlphaFold 확인

측정 많은 타겟 20개의 버전, 평균 pLDDT, pLDDT 70 초과 비율

3

정제 규칙 확정

16장 일곱 가지를 ML 트랙과 합의해 W04(10/31)에 동결

참고 자료

References · 데이터 출처

1. BindingDB in 2024: a FAIR knowledgebase of protein–small molecule binding data. *Nucleic Acids Res* (2025)

2. BindingDB Download 페이지 (2026-09-29 갱신, 2026-10-23 확인). bindingdb.org

3. AlphaFold Protein Structure Database 2025: a redesigned interface and updated structural coverage. *Nucleic Acids Res* 54:D358 (2026)

4. AlphaFold DB release notes, v6 (2025-10-21). ebi.ac.uk/pdbe

5. Huang et al. Therapeutics Data Commons. arXiv:2102.09548 (2021)

6. Davis et al. Comprehensive analysis of kinase inhibitor selectivity. *Nat Biotechnol* 29 (2011) · DeepDTA 저장소의 Kd 행렬

7. Huang et al. MolTrans: molecular interaction transformer for DTI prediction. *Bioinformatics* (2021) · 저장소 dataset/BindingDB

8. Himmelstein. dhimmel/bindingdb: BindingDB 2015-10 처리본 (GitHub, CC0)

9. Wallach & Heifets. Most ligand-based classification benchmarks reward memorization rather than generalization. *JCIM* (2018)

단백질은 20글자 알파벳으로 쓴 문장입니다



글자 하나 = 아미노산 하나 = **잔기(residue)**. 색: 주황 = 기름을 좋아함(소수성) · 청록 = 전하를 띰 · 회색 = 그 밖

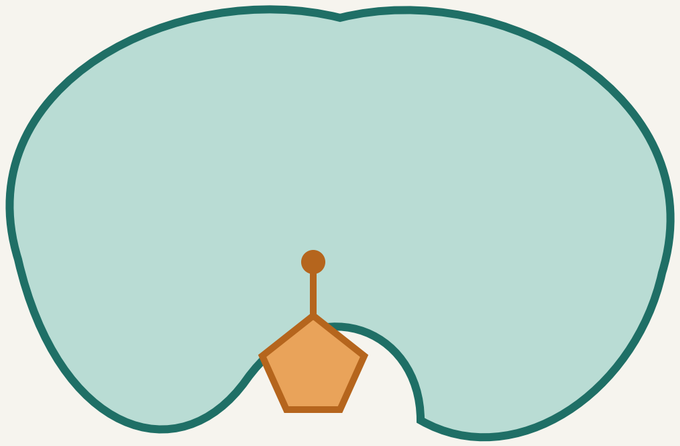
AI 말로 바꾸면

어휘 크기 20(+특수 토큰)의 토큰 열. 문장 길이는 보통 수백 토큰. 토크나이저는 자연이 이미 정해 두었습니다.

자연어와 다른 점

글자마다 물리적 성질(크기, 전하, 물을 싫어하는 정도)이 있고, 이 성질이 다음 계단의 "접힘"을 결정합니다.

약은 단백질 표면의 오목한 자리, pocket에 들어갑니다



청록 = 단백질 · 주황 = 약물(리간드)

열쇠와 자물쇠

결합은 모양과 화학(수소결합, 소수성)의 궁합입니다. DTI 예측이 맞히려는 것이 바로 이 궁합입니다

apo와 holo

약이 없는 상태(apo)와 결합한 상태(holo)는 pocket 모양이 다를 수 있습니다. 자물쇠가 열쇠에 맞춰 조금 변형되는 셈입니다

그래서 우리 프로젝트는

단백질 전체가 아니라 pocket 주변의 구조 신뢰도만 봅니다 → "구조 신뢰도" 좌표

실험으로 구조를 푸는 일은 느리고 비쌉니다

발현·정제 → 결정화 → X선 회절 → 전자밀도 지도 → 원자 모델 (PDB)

약 20만

실험으로 푼 구조(PDB). 구조 하나에 수개월에서 수년

수억

시퀀싱으로 알려진 서열(UniProt, 메타게놈). 매일 늘어남

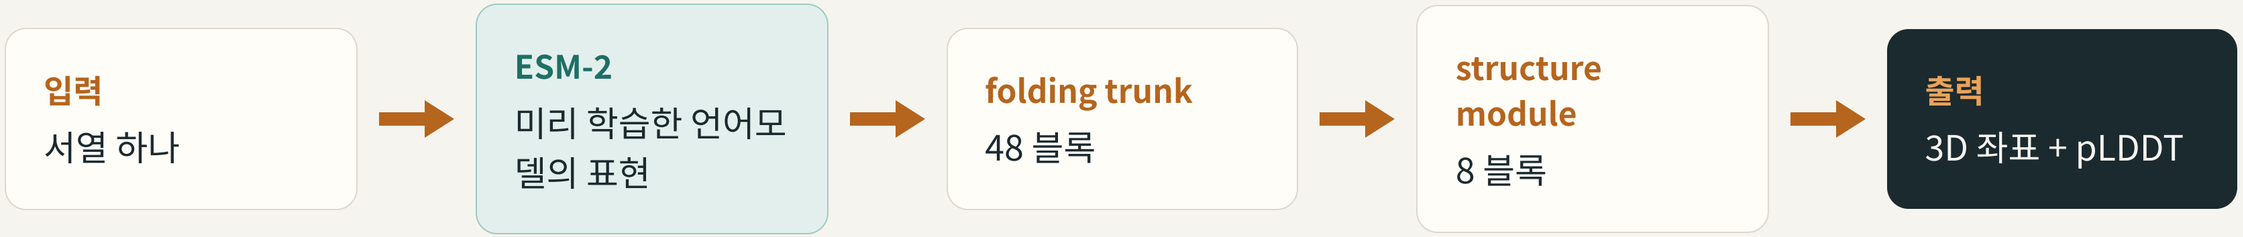
AI 말로 바꾸면

라벨(구조)은 적고 라벨 없는 데이터(서열)는 넘칩니다. 자기지도학습이 빛나는 조건입니다

ESM-2 · Lin et al., Science 2023 · abstain-dti W02 · 18 · 구조·서열 수는 대략값 (2025년 기준 일반 통계)

부록 · Fig. 2A · ESMFold 구조

AF2의 MSA 처리부를 언어모델 한 번으로 바꿨습니다



출력을 다시 입력으로 돌리는 recycling 3회

folding block 안에서

잔기별 표현(Seq Rep)과 잔기 쌍 표현(Pair Rep, L×L)을 번갈아 갱신. triangular update는 "i–j, j–k가 정해지면 i–k도 제약된다"는 거리의 삼각 관계를 학습

무엇으로 학습했나

2020-05까지의 PDB 단일 사슬 약 32.5만 개 + AF2 예측 구조 약 1,200만 개(pLDDT 70 초과만). 손실 함수는 AF2와 동일

속도 (Fig. S2)

V100 한 장, 384잔기 14.2초로 AF2 단일 모델의 6배. 짧은 서열은 최대 약 60배. MSA 검색 시간(10분 이상)은 별도

부록 · Table S4 · CAMEO 난이도별

쉬운 문제에선 AF2와 비슷, 어려운 문제에선 격차가 커진다

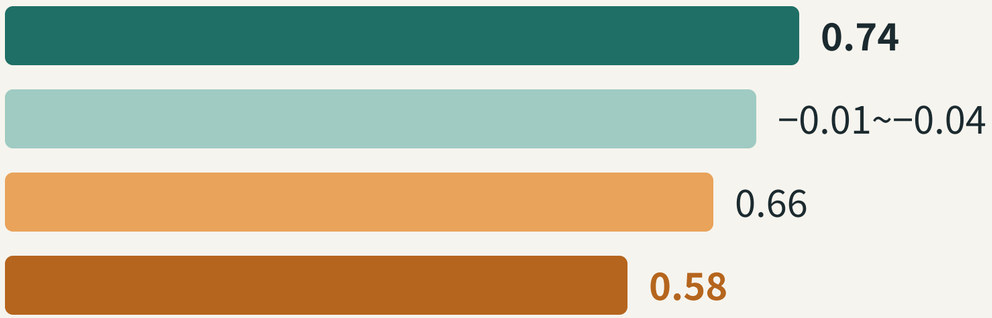
평가셋 (구조 수)	MSA 깊이 (UniRef 중앙값)	ESMFold	AF2	격차
CAMEO easy (97)	17,627	0.90	0.93	0.03
CAMEO medium (89)	860	0.79	0.86	0.07
CAMEO hard (8)	56	0.45	0.62	**0.17**
CASP14 (51)	161	0.68	0.85	**0.17**

평균 TM-score. MSA 깊이는 AF2 파이프라인 기준. CAMEO의 절반은 모두가 잘 푸는 easy이고, 난이도 등급은 공개 서버들의 평균 LDDT로 매긴 "사후 난이도"입니다(부록 A.1.4). MSA 깊이는 문제를 풀기 전에 알 수 있는 "사전 난이도"에 가깝습니다.

부록 · Fig. S3 · 부품을 하나씩 뺐을 때

언어모델을 빼면 성능이 가장 크게 무너집니다

CAMEO LDDT (folding trunk 8블록 설정)



"그 외 4종"

AF2 예측 구조로 학습 안 함, recycling 끄기, triangular update 없음, structure module 1블록. 모두 작은 하락

CASP14에서도 같은 순서. 구조 예측 실력의 대부분이 언어모델에서 온다는 근거

ESM-2 · Lin et al., Science 2023 · abstain-dti W02 · 21 · 수치는 본문 p.6, 막대 길이는 LDDT에 비례

부록 · Fig. 4 · 메타게놈 예측 사례

두 모델은 거의 같은 답을 내는데, PDB에는 닮은 구조가 없습니다

4A · ESMFold를 AF2와, 그리고 Foldseek 최근접 PDB와 비교

MGnify ID	vs AF2 RMSD · TM	최근접 PDB	vs PDB RMSD · TM
MGYP000279975524	0.59 Å · 0.99	4L5S_B	5.4 Å · 0.49
MGYP000712274586	0.49 Å · 1.0	1TTG_A	5.0 Å · 0.45
MGYP001220175542	1.0 Å · 0.98	5Y1X_A	6.4 Å · 0.38
MGYP001812528822	1.1 Å · 0.98	5HH3_C	11 Å · 0.39
MGYP000706186022	0.85 Å · 0.96	1XKS_A	5.8 Å · 0.47
MGYP000911143359	1.2 Å · 0.94	5NNI_A	5.8 Å · 0.67

4B–C · 서열 친척 없이 구조로 찾은 기능

MGYP000936678158
UniRef90 매치 없음 → 세균 뉴클레아제(3H4R_A)와 TM 0.67

MGYP004000959047
UniRef90 매치 없음 → 세균 스테롤 결합 도메인(6BYM_A)과 TM 0.80

서열은 빨리 변하고 구조는 오래 보존됩니다. 그래서 서열 검색으로 안 보이는 먼 친척을 구조로 찾아 기능 가설을 세울 수 있습니다. 단, 두 모델의 일치는 정답의 증거가 아닙니다.

부록 · 용어 한눈에

발표 중 나온 용어 16개

잔기 (residue) 사슬 속 아미노산 하나 = 토큰 하나

1·2·3차 구조 서열 / 나선·병풍 같은 국소 무늬 / 접힌 3D 전체

pocket · apo / holo 약이 들어가는 오목한 자리 / 약 없는 상태 / 결합 상태

PDB 실험으로 푼 구조 저장소. 구조 예측의 정답지

MSA 같은 단백질의 친척 서열을 줄 맞춘 표

공진화 3D에서 맞닿은 잔기 쌍이 함께 변하는 현상

접촉 지도 잔기 쌍의 Cα 거리가 8 Å 안인지 표시한 L×L 행렬

RMSD 원자 위치 평균 오차 (Å). 낮을수록 좋음

TM-score 전체 접힘 겹침 (0–1). 0.5 이상이면 fold 정답

LDDT · pLDDT 국소 정확도 / 모델이 예측한 그 값 (자기 확신)

PAE 잔기 쌍 상대 위치의 예상 오차

Masked LM 서열의 15%를 가리고 맞히는 자기지도학습

임베딩 잔기마다 나오는 숫자 벡터. 650M 모델은 1280차원

Perplexity 서열을 얼마나 아는가. 1 = 완벽, 20 = 무작위

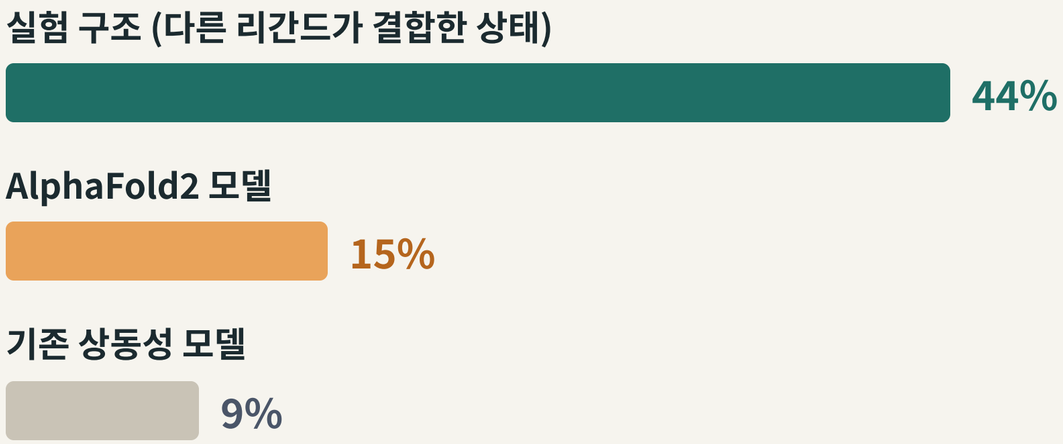
UniRef50 / 90 서열 identity 50% / 90%로 묶은 UniProt 클러스터

CASP14 · CAMEO 2020년 5월 이후 공개된 구조 51개 / 194개로 만든 시험셋

부록 · 근거 1 · 구조가 맞아도 결합은 다른 문제

AlphaFold2가 pocket을 잘 그려도, 약의 자세는 잘 못 맞혔습니다

GPCR 18종, 실험 구조 54개에 리간드를 도킹해 자세 오차 2 Å 이하를 성공으로 셈



AF2와 상동성 모델의 차이는 통계적으로 유의하지 않음 (p > 0.5)

1.3 Å

AF2 모델의 pocket RMSD 중앙값 (상동성 모델은 3.3 Å). 구조 자체는 매우 정확

우리에게 주는 뜻

구조 정확도(RMSD)로는 도킹 성공을 잘 예측할 수 없었습니다. 구조 신뢰도는 난이도의 한 축이지, 결합에 대한 확신은 아닙니다

ESM-2 · abstain-dti W02 · 24 · Karelina, Noh & Dror, eLife 12:RP89386 (2023)

부록 · 근거 2 · 분포가 바뀌면

처음 보는 데이터 앞에서는 성능도, 확신도 부풀려지기 쉽습니다

Wallach & Heifets, JCIM 2018

random split은 암기를 보상한다

학습셋과 검증셋이 닮을수록 성능이 높게 나옴. 널리 쓰인 벤치마크 7개에서 이 중복(AVE bias)과 성능이 강하게 상관

→ cold split이 필요한 이유

Guo et al., ICML 2017

현대 신경망은 과신한다

깊고 넓은 최신 모델일수록 확신이 정답률보다 높음. 학습 후 temperature scaling 하나로 같은 분포에선 잘 고쳐짐. ECE의 출처

→ 보정은 측정하고 고칠 수 있다

Ovadia et al., NeurIPS 2019

그런데 분포가 바뀌면 깨진다

사후 보정만으로는 분포가 바뀐 데이터에서 확신을 믿을 수 없게 됨. 여러 모델을 함께 쓰는 방법(앙상블 등)이 가장 강했음

→ cold split = 분포 이동

ESMFold의 좋은 보정(pLDDT–LDDT 0.86)은 학습과 비슷한 단백질에서 잰 값입니다. **처음 보는 타겟에서도 유지되는지는 아무도 재지 않았고, 그게 우리 벤치마크입니다.**

ESM-2 · abstain-dti W02 · 25 · README 부록 A-3, A-4의 필독 문헌

부록 · ESM-2 다음 단계 · 구조를 알파벳으로

서열 글자 옆에 구조 글자를 붙이면 언어모델이 구조도 읽습니다

아미노산 M K T A Y I A K

3Di 구조 d v v l p c q d

합친 토큰 Md Kv Tv Al Yp Ic Aq Kd

예시 표기. 3Di 글자는 실제 구조에서 Foldseek가 계산

Foldseek: 3Di 알파벳

각 잔기가 3D에서 가장 가까운 이웃과 맺는 관계를 20글자로 표기. 구조 검색을 서열 정렬처럼 할 수 있어 Dali보다 약 18만 배 빠르고, 민감도는 Dali의 86%

SaProt: 구조 인식 어휘

아미노산 토큰과 3Di 토큰을 합친 어휘로, 서열·구조 약 4천만 개를 학습. 10개 하위 과제에서 기존 기준선을 넘었다고 보고

우리 프로젝트에서

AlphaFold 활용 2단계(SaProt·ESM-IF)가 이것. 질문: 구조 토큰을 더하면 처음 보는 타겟에서 확신이 더 정직해질까?

ESM-2 · abstain-dti W02 · 26 · van Kempen et al., Nat Biotechnol 2024 · Su et al., ICLR 2024

참고문헌

References

1. Lin et al. Evolutionary-scale prediction of atomic-level protein structure with a language model. *Science* 379 (2023). doi:10.1126/science.ade2574

2. Karelina, Noh & Dror. How accurately can one predict drug binding modes using AlphaFold models? *eLife* 12:RP89386 (2023)

3. Terwilliger et al. AlphaFold predictions are valuable hypotheses… *Nat Methods* 21 (2024). doi:10.1038/s41592-023-02087-4

4. Wallach & Heifets. Most ligand-based classification benchmarks reward memorization rather than generalization. *JCIM* (2018)

5. Guo et al. On calibration of modern neural networks. *ICML* (2017)

6. Ovadia et al. Can you trust your model's uncertainty? *NeurIPS* (2019)

7. van Kempen et al. Fast and accurate protein structure search with Foldseek. *Nat Biotechnol* (2024)

8. Su et al. SaProt: Protein language modeling with structure-aware vocabulary. *ICLR* (2024)

9. Singh, Sledzieski et al. Contrastive learning in protein language space predicts interactions between drugs and protein targets. *PNAS* 120 (2023)

10. A large dataset curation and benchmark for drug target interaction. arXiv:2401.17174 (2024)

11. Ding & Steinhardt. Protein language models are biased by unequal sequence sampling across the tree of life (2024)

부록 · 오늘의 순서

아미노산 한 글자에서 논문까지, 일곱 계단



1–5는 생물학, 6–7은 AI와 만나는 지점입니다. 이 계단을 오르면 논문이 한 장으로 읽힙니다.